

TrackWise——新时代智慧教育的高效辅助方案

摘要

随着人工智能和大数据技术的迅猛发展，智能教育正在成为教育领域的重要发展方向。本项目旨在设计并实现一个名为TrackWise的智能导学系统，通过融合先进的人工智能技术和教育理论，为学生提供个性化的学习体验和精准的教育资源推荐。

本系统基于知识空间、最近发展区和建构主义理论，采用领域知识层、基础模型层和用户接口层的分层架构。基础模型层实现了三个核心功能：结合LSTM和大模型P-Tuning的自动阅卷评分模型，采用KTPromptCast技术的知识追踪模型，以及基于纵向联邦学习和BERT的教育-就业匹配模型。系统还集成了ChatGLM2-6B模型，通过RLHF技术生成解题范例，并实现了基于协同过滤的个性化题目推荐和动态知识图谱构建。

技术实现采用Spring Boot后端、Vue.js前端和Neo4j图数据库，并集成Redis缓存和Mybatis Plus ORM工具优化性能。实验评估显示，自动阅卷评分模型准确率达82.13%。

本项目的主要创新点包括：（1）融合多种教育理论，构建智能教育的科学基础；（2）设计混合自动阅卷模型、KTPromptCast知识追踪技术、应用联邦学习于教育-就业匹配，以及集成大规模语言模型提升交互能力；（3）采用分层设计，实现高度模块化和可扩展的系统结构；（4）知识追踪模型性能指标超过多个基线模型；（5）形成完整的智能教育解决方案，具有较高的市场潜力和应用价值。

关键词：LLM，知识追踪，智能导学，自动阅卷

目录

1 前言	1
2 技术背景	2
2.1 教育学理论基础	2
2.1.1 知识空间理论	2
2.1.2 最近发展区理论	2
2.1.3 建构主义理论	2
2.2 自动阅卷评分技术	3
2.3 大模型实现知识追踪及融合时间序列的研究现况	4
3 技术方案	7
3.1 领域知识层	8
3.2 基础模型层	8
3.2.1 基于大模型和LSTM的自动阅卷评分模型	8
3.2.2 基于大模型知识追踪的学习者模型	14
3.2.3 基于联邦学习的教育—就业匹配模型	18
3.3 用户接口层	20
3.3.1 基于大模型RLHF生成多样范式	20
3.3.2 基于协同过滤算法的个性化题目推荐	21
3.3.3 个性化学习导航	25
4 系统实现	27
4.1 系统架构	27
4.2 技术栈	28
4.3 数据集	29
4.4 数据流程	30
4.5 数据库设计	30
4.6 后端设计	31
4.7 平台介绍	32
4.7.1 首页界面	32
4.7.2 登录注册界面	34
4.7.3 知识图谱页面	35
4.7.4 功能页面	36
4.7.5 作答界面	37
4.7.6 用户信息页面	39

4.7.7 博客页面	40
5. 创新与特色	42
5.1 创意	42
5.1.1 设计理念	42
5.1.2 题的创新性	42
5.2 技术	42
5.2.1 先进性	42
5.2.2 综合性	43
5.3 实用	43
5.3.1 实用价值	43
5.3.2 市场潜力	43
5.4 设计	43
5.4.1 技术路线	43
5.4.2 系统架构	44
5.4.3 用户界面	44
5.5 效果	44
5.5.1 系统功能的有效性	44
5.5.2 系统功能的复杂度	45
参考文献	46
附录	47
附录一：项目投资意向书一	47
附录二：项目投资意向书二	48
附录三：项目投资意向书三	49
附录四：国家级大学生创新创业训练计划竞赛项目1项	50
附件五：第十五届蓝桥杯全国软件和信息技术专业人才大赛数字科技创新赛全国选拔赛三等奖	50
附录六：2024网络技术挑战赛华南赛区三等奖	51
附件七：华南师范大学中国国际大学生创新大赛（2024）校赛铜奖	52

1 前言

在当前数字化浪潮席卷全球的背景下，我国教育行业正迎来前所未有的发展机遇。从国家层面到地方层面，一系列政策文件明确指出了数字化、信息化、智能化在教育领域的重要性和发展方向。

首先，数字化政策为数字文化合作发展提供了坚实支撑。从《关于推进实施国家文化数字化战略的意见》到“十四五”规划的明确提出，国家正大力构建线上线下融合的文化服务供给体系，并致力于建成全面共享的国家文化大数据体系。广东省政府也积极响应，通过《关于加快数字化发展的意见》等文件，全面推进经济社会各领域的数字化转型发展，特别是在数字生态、数字经济、数字社会、数字政府等方面取得了显著成效。

其次，信息化时代的到来促使传统教育变革。教育部及多项国家政策强调推进教育数字化、现代化的紧迫性和必要性。随着固定宽带家庭普及率和移动宽带用户普及率的不断增长，我国网民规模及互联网普及率也呈现出快速增长的趋势，中国互联网络信息中心（CNNIC）在京发布第53次《中国互联网络发展状况统计报告》显示，截至2023年12月，我国网民规模达10.92亿人，较2022年12月新增网民2480万人，互联网普及率达77.5%，为数字教育的普及和发展提供了有力保障。党的二十大报告部署了“实施科教兴国战略，强化现代化建设人才支撑”的重要任务，作出了“教育、科技、人才是全面建设社会主义现代化国家的基础性、战略性支撑”的新论断，提出了加快建设“网络强国”“数字中国”“推进教育数字化”的重要任务。

再者，智能化教育为人才培养注入了新的活力。《中国智慧教育蓝皮书》深刻阐述了智慧教育作为数字时代教育新形态的核心价值，包括其在核心理念、体系结构、教学范式、教育内容和教育治理等方面的创新。智慧教育不仅关注个性化学习，还强调集体智慧和资源共享，通过构建学习共同体，实现规模化教育与个性化培养的有机结合。

最后，学习共同体和资源共享成为推动教育均衡发展的重要途径。国家政策强调在保障基本公共教育服务的同时，注重内涵发展和资源配置方式的优化。通过加快智慧教育平台建设，构建互联互通、共建共享的数字教育资源平台体系，有效扩大优质教育资源覆盖面，促进教育资源的均衡分配和高效利用。

因此，本项目致力于提出一个新时代智慧教育的高效辅助方案。通过运用最新的人工智能技术，如深度学习、自然语言处理等，构建一个功能丰富、互动性强的智能学习环境，推动教育行业的新质生产力。

2 技术背景

2.1 教育学理论基础

2.1.1 知识空间理论

知识空间理论（KST）为智能导学系统提供了一种底层知识结构支撑和信息组织框架，使得这些系统能够有效地管理和推荐学习内容。根据Albert和Lukas的原始构想（1999），知识空间理论可以帮助系统识别和组织知识单元，以及它们之间的依赖关系。通过这种方式，智能导学系统能够根据学生当前的知识状态，动态地推荐下一步最合适的学习材料。Koppen（1998）进一步扩展了这个理论，通过建立复杂的知识结构，使得教育技术能够更好地适应不同学生的学习路径。此外，Hockemeyer 等（1999）描述了一个基于知识空间理论的计算模型，该模型能够实时更新学生的知识状态，并据此调整教学策略，以达到最佳的学习效果。这些研究成果表明，知识空间理论不仅可以支持智能导学系统在知识组织和路径规划方面的需求，还可以增强系统的个性化学习功能，从而提供更加有效和针对性的教学支持。

2.1.2 最近发展区理论

维果斯基的最近发展区理论区分了两个发展水平：实际发展水平和潜在发展水平。实际发展水平是学习者能够独立解决问题的能力水平，而潜在发展水平是在有经验的他人帮助下，学习者能达到的更高能力水平。ZPD是这两者之间的差距，是教育干预可以发挥作用的关键区域，代表了学习者在适当支持下能够达到的潜力（Vygotsky, 1967）。教育者利用 ZPD 理论来设计教学策略，通过提供恰到好处的指导和支持，帮助学生达到他们的潜能。这种教学策略鼓励更高水平的思维技能，如批判性思维和问题解决能力，是推动认知发展的重要手段（Wood, Bruner, & Ross, 1976）。随着技术的发展，智能导学系统开始集成 ZPD理论，以提供更加个性化的学习体验。这些系统通过分析学生的互动和学习成 果，识别每个学生的 ZPD，并据此调整教学内容和难度，确保教学活动既不超出学生的潜在发展水平，也不低于学生的实际发展水平。例如，系统可能会根据学生的响应动态调整问题的难度，或者提供适时的提示和反馈（Koedinger & Corbett, 2006）。国际上，研究者们已经广泛探讨了 ZPD 在多种教育环境中的应用，如线上学习、虚拟现实和协作学习 环境。研究表明，正确应用 ZPD 理论可以显著提高学生的学习效果和动机（Palincsar, 1998）。在中国，研究主要集中在如何将 ZPD 理论与中国传统的教育实践相结合，探索其在大班额和应试教育环境中的应用可能性（Wang & Lin, 2012）。

2.1.3 建构主义理论

建构主义理论主张知识不是简单地从外界被动接收，而是通过个体与环境之间的互动过程主动构建的（Piaget, 1954; Vygotsky, 1978）。其中，认知建构主义由皮亚杰提出，强调个体通过同化和顺应的过程在与环境互动中重构认知结构。社会建构主义则由维果斯基提出，突出社会互动在认知发展中的作用，并提出了最近发展区的

概念，即个体在更有经验者的帮助下可以达到更高的认知水平 (Vygotsky, 1978)。在教育领域，建构主义理论推崇以学习者为中心的教学方法，如探究式学习和协作学习 (Bransford, Brown, & Cocking, 2000)。这些方法鼓励学生在真实情境中主动探索和构建知识，从而促进深层次的认知和技能发展。教育者被视为引导者或协助者，而不仅仅是信息的传递者。随着技术的发展，智能导学系统开始采用建构主义原则设计用户界面，以支持个性化学习和探索性学习 (Chen, 2009)。这些系统通过提供模拟环境、实时反馈和适应性学习路径，帮助学生根据自己的需求和认知发展阶段进行学习。例如，智能导学系统可以通过分析学生的学习历程数据来调整教学策略，以适应学生的个性化学习需求 (Wang, 2011)。在国际上，许多研究已经证明了建构主义理论在提高学生的批判性思维、问题解决能力及自主学习能力方面的有效性 (Hmelo-Silver, 2004)。而国内研究则集中在如何将这些理论整合到传统的教学体系中，并探索智能导学系统在大规模教育环境中的应用可能性 (Li & Chen, 2014)

2.2 自动阅卷评分技术

自动阅卷评分系统主要分为两类：一类基于人工设计的特征，另一类则依赖于神经网络技术。首先，以 E-rater 为例，这是一个由 ETS 的 Jill Burstein 博士及其团队开发的系统，首次在 2006 年详细介绍。E-rater 采用自然语言处理 (NLP) 和信息检索 (IR) 技术，目前已应用于 TOEFL 考试的作文评分。这种系统通过分析文章的语法、用法、结构等多种特征，利用这些特征的标准化加权平均数进行评分。然而，这种方法需要大量时间来开发和调整特征集，并可能面临被测试者根据已知的评分特征刻意编写文章以获取高分的挑战。另一类方法是基于神经网络的自动评分系统，例如 Kaveh Taghipour 等人在 2016 年的研究中提出，他们使用递归神经网络（包括 LSTM 和 CNN 组合模型）来自动从文本中提取特征并进行评分。这种端到端的方法不依赖于人工特征，因此可以减少人为偏见，并具有更好的适应性和鲁棒性。但是，这种模型的缺点包括训练时间长，参数众多，且结果解释性较差。

对于主观题阅卷技术的研究，目前已经有了较多的方法，例如人工特征集，和采用神经网络提取特征并通过有监督学习构建自动阅卷模型的方式。但虽然制定人工特征集的方式能够使得人类评分者可以评估各种感兴趣的内在变量，但是特征集的制作过程较为复杂，虽然在 Jill Burstein 博士团队研究的 e-rater 中，自动阅卷评分的准确度已经高于 90%，但是构建人工数据集的成本太高，不符合我们研究的预期。因此，我们还可以采用构建神经网络的方式对主观题进行自动阅卷评分，在 Kaveh Taghipour 等人研究报告中，基于 CNN 与 LSTM 结合的神经网络在对主观题自动阅卷评分的任务中已经达到了 76.1% 的准确度了，这也达到了我们研究的预期值。然而采用神经网络的方式虽然不需要制定人工特征集，但是需要较大的数据集进行训练，存在训练参数较多、训练时间较长以及训练集制作成本较高的问题。由此，对于自动阅卷模型的研究，我们还可以引入预训练模型，对预训练模型进行微调，然后应用于自动阅卷的任务中。这

样的方式可以不仅降低神经网络训练的难度，提高训练的成功概率，还可以提高我们此次研究的效率并提高落地可行性。

基于上述对国内外研究现状预研及存在问题的描述，我们对现有的一些主要技术路线的优势和存在问题进行汇总，制成下列表格：

表3-1-1 自动阅卷评分技术国内外研究现状

团队	技术方法	采用该技术的优点	采用该技术的缺点
Jill Burstein	构建特征集，把得分计算为标准化特征值的加权平均值	人类评分者可以直接评估各种感兴趣的内在变量，评分结果与人为评分结果更加接近，训练时间短	需要自定义评分的特征并耗费大量时间构建特征集
Kaveh Taghipour	构建递归神经网络	不用花大量时间设定人工特征集，鲁棒性更高	训练时间过长需要大量参数
Youmna Farag	一个集成 LSTM&N 模型与局部相干性模型的框架，两个模型 共同训练	在预测分数同时，还能标记对抗性输入，提高评分模型鲁棒性	训练耗时长，训练数据集需求大
JIN XUE	基于对BEST预训练语言模型进行微调的迁移学习	在数据集较小或者存在缺陷时，提高训练效果，缩短训练时间。提高模型鲁棒性，实现跨课程群的阅卷评分	无
Scott Hellman	采用基于池的抽样的主动学习范式	用更小但更有效的训练数据集对模型进行自发的再训练，显著减少标注代价	无

2.3 大模型实现知识追踪及融合时间序列的研究现况

对于利用大模型实现知识追踪算法来说，Neshaei等人已经初步探讨了LLMs是否可以应用于学生表现预测领域。他将知识追踪视为一种时序预测任务，证明了大型语言模型（LLM）能够对学生的成绩进行建模，并对未来行为做出有用的预测，尽管他们表现最好的方法在真实世界的数据集上没有取得最先进的结果，但它们的性能与贝

叶斯知识追踪（BKT）大致相当，并且可靠地击败了一组naive baselines，结果表明，LLMs 可以作为知识追踪算法和学生表现预测的新方法系列的基础。

在这个框架中，我们通过分析学生与教育内容的交互序列来追踪其知识状态的演变。大模型可以从时间序列数据中提取关键特征，整合来自不同数据源的信息，从而提供更全面、更准确的时间序列预测。这其中，由于LLMs原始文本数据与实践序列数据存在数值特性之间的差距，如何将时间序列数据输入大模型就成了实现LLMs在时间序列预测领域应用的关键性问题。将时间序列与LLM融合的方式有两条路线：

- ①. LLM-for-TS：针对TS数据，从头开始设计并预训练一个基本的大型模型，然后为各种下游任务相应地微调模型；
- ②. TS-for-LLM：基于现有的LLM，使它们能够处理TS数据和任务。不是创建一个新的LLM，而是设计一些机制来为LLM 定制TS。

已有的通过大模型在特定领域融合时间序列的文献如下：

表3-1-2 大模型在特定领域融合时间序列国内外研究现状

领域	团队	研究成果	摘要
交通	Hao Xue 等人	Xue, H., Voutharoja, B. P., & Salim, F. D. (2022). Leveraging language foundation models for human mobility forecasting.	作者设计了一个AuxMobLcast的方法，通过引入特定的提示将数值时间序列转换为句子，使现有的语言模型可以直接应用于预测任务。
金融	Xinli Yu 等人	Yu, X., Chen, Z., Ling, Y., Dong, S., Liu, Z., & Lu, Y. (2023). Temporal data meets LLM – Explainable financial time series forecasting.	利用历史股价、公司元数据和经济新闻，通过大型语言模型（LLMs）结合链式推理技术，进行金融时间序列零次或少次学习推理和指导性微调，展示了LLMs在解决金融时间序列预测中的潜力。
金融	Qianqian Xie 等人	Xie, Q., Han, W., Lai, Y., Peng, M., & Huang, J. (2023). The Wall Street Neophyte: A Zero-Shot Analysis of ChatGPT Over Multi-Modal Stock	通过零次射击分析，测试了ChatGPT处理股票价格预测的能力，并考察了是否结合推文信息能够提高其预测性能。尽管引入了“思维链”提示策略，其性能提升并不显著。

		Movement Prediction Challenges.	
金融	Boyu Zhang 等人	Zhang, B., Yang, H. (Bruce), & Liu, X.-Y. (2023). Instruct-FinGPT: Financial Sentiment Analysis by Instruction Tuning of General-Purpose Large Language Models.	提供了一种指令模板，通过将一小部分有监督的金融情感分析数据转化为指令数据，并使用该方法微调通用大型语言模型，显著提高了金融情感分析的效果。
医疗	Xin Liu 等人	Liu, X., McDuff, D., Kovacs, G., Galatzer-Levy, I., Sunshine, J., Zhan, J., Poh, M.-Z., Liao, S., Di Achille, P., & Patel, S. (2023). Large Language Models are Few-Shot Health Learners.	证明只需进行少数几次调整，大型语言模型就能够将各种生理和行为时间序列数据与文本联系起来，并在临床和健康领域对许多健康任务进行有意义的推断。
医疗	Jun Li 等人	Li, J., Liu, C., Cheng, S., Arcucci, R., & Hong, S. (2023). Frozen Language Model Helps ECG Zero-Shot Learning.	设计了一种结构化的提示模板，用来指导大型预训练语言模型理解和处理输入的临床报告文本。通过最大化配对ECG和自动生成的报告之间的相似度，最小化ECG和其他报告之间的相似度，实现了在不使用任何注释数据的情况下进行零次分类。

通过文献调研可知，基于 LLMs 的在特定领域的时间序列预测任务主要是基于 TS-for-LLM 路线，利用直接提示 LLMs 的方法，将时间序列数据作为文本输入到模型中，以引导模型输出针对数据的预测结果，结合思维链实现时间序列预测。相较于使用海量时间序列数据重新训练一个时间序列领域的大模型，直接利用现有的 NLP 领域训练好的大模型，通过设计 prompt、将时间序列数据转换成大模型理解的文本，实现时间序列预测。后者的代价更小，且有成熟的可供使用的大模型，因此得到了很多研究

者的青睐。在基于 Prompt 方法中, Hao Xue 等人首次从自然语言生成的角度解决了时间序列预测问题, 提出了基于提示的时间序列预测 (PromptCast)。传统的时间序列预测方法通常将数值序列作为输入, 并生成数值作为输出。他们则将输入和输出转化为提示, 并以句子对句子的方式进行预测, 从而可以直接应用语言模型进行预测。

因此本项目将结合 PromptCast 范式, 将 Neshaei 研究中的 LLM 性能评估结果作为基线, 同时对比 naive baselines 及其他四种传统知识追踪模型 (BKT、Best-LR、DKT、SAKT) 性能, 设计出在知识追踪中能有效提高模型性能的 KTPromptCast

3 技术方案

本项目的智能导学系统构建基于一种层次化的方法, 每一层都为上层提供支持和数据, 确保系统的整体功能协同高效地工作。第一层, 领域知识层, 是整个系统的基础。它提供了详尽的学科知识库和教学策略库, 这些库中包含了教育内容的结构化描述和应用方法。通过知识空间理论的应用, 这一层能够构建起知识点间的关联和逻辑框架, 形成一个全面的知识网络, 这不仅帮助系统理解教育内容的深度和广度, 同时也为上层的教学和学习提供精确的基础数据。第二层, 基础模型层, 基于最近发展区理论, 依赖于第一层提供的丰富、结构化的教育内容进行功能实现。知识追踪模型使用第一层中的知识点和认知关系来跟踪和预测学习者的知识掌握状态。自动阅卷评分模型和基于联邦学习的教育-就业匹配模型则利用教学策略库中的数据, 如学习路径和学科能力, 来提供个性化的教学干预和评估。第三层, 用户接口层, 基于建构主义理论构建。系统直接与用户互动, 提供直观的操作界面和个性化 的反馈。这一层的功能依赖于前两层的数据和模型输出。利用大模型RLHF生成多样范例以及利用协同过滤算法进行个性化推荐, 帮助用户更好的掌握知识点, 提高学习效率和兴趣。此外, 个性化知识图谱构建则结合了领域知识层的结构化知识和基础模型层的用户学习数据, 为每位用户创建一个定制的学习路线图。

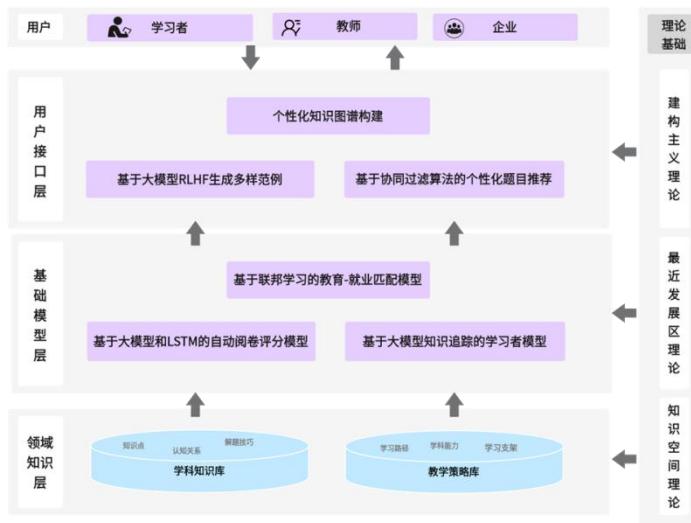


图3-1 技术路线图

3.1 领域知识层

领域知识层是智能导学系统的核心，它基于知识空间理论，整合了学科知识库和教学策略库，旨在表征、存储和管理相关知识与信息。通过构建分层教育知识图谱，结构化组织学科知识、教学策略和教学目标等关键信息，明确实体间的逻辑关系，如知识点间的前驱后继关系、包含关系等，为学习者提供结构化和个性化的学习路径。数据集分为已标注知识点和未标注知识点。对于未标注知识点的数据集主要采用条件随机场（Conditional Random Field, CRF）等技术对知识点等实体进行自动提取。参考陈鹏鹤等（Chen et al., 2018）的工作。标注好知识点后，采用人机耦合的方式构建分层知识图谱。利用大模型能够理解复杂文本和挖掘细微关系的能力来自动识别学科知识点间的关键逻辑关系，如前驱后继关系。教学策略库主要涵盖学习路径和学习支架信息，其中学习支架主要包括解决问题的提示以及示例。领域知识层是智能导学系统的知识基础与数据来源，为基础模型层和用户接口层提供了结构化学科知识、教学资源和测评性数据。

3.2 基础模型层

3.2.1 基于大模型和LSTM的自动阅卷评分模型

1、基于LSTM的循环神经网络模型

基于LSTM（Long Short-Term Memory）的递归神经网络模型由四部分组成：

Step1:基于BERT的预训练语言模型；对于预训练语言模型，我们只用预训练语言模型获得文本的张量表示，并采用Frozen形式，锁住预训练语言模型的参数，只训练后面的自定义的LSTM递归神经网络模型；

Step2:基于LSTM的递归神经网络模型；

Step3:一个自定义的成绩计算函数；我们的LSTM递归神经网络模型是一个用softmax函数输出的分类模型，我们将成绩分为六类（A、B、C、D、E、F），对应六个分数值（100、85、70、55、40、25）；

Step4;根据softmax函数输出的六个概率向量用成绩计算函数计算成绩。

下面，我们对LSTM递归神经网络模型的各个部分进行介绍：

① . 基于BERT的预训练模型

在训练自动阅卷评分模型时，我们将考生答案的数据交给算法，算法给出评分，通过比对算法给出的分值和人为评分的分值的差距，并通过损失函数进行训练。但由于用于训练的数据集大小有限，因此我们需要采用预训练技术，使得自动阅卷模型的机器学习算法在开始使用训练数据集进行训练之前拥有一定的预测能力并对文本进行特征提取，之后再调用训练模型进行训练。在此次研究中，考虑到我们用的训练集较小且数据集与预训练模型所采用的数据集并不相似，因此我们采用Frozen形式，用基于BERT的预训练语言模型来获取输入文字段落的文本张量表示，并锁定预训练语言

模型的参数，只训练并更新自定义的LSTM递归神经网络模型的参数。考虑到训练和测试数据集均为中文文本的形式，因此我们将使用基于transformer的bert-base-chinese预训练模型对训练数据集进行预训练，增强了自动阅卷模型训练的效果。

②. 基于LSTM的循环神经模型

我们选择使用LSTM（Long Short-Term Memory）循环神经网络模型是因为我们处理的主观题是较长的文字序列，且有部分开放性主观题。传统的CNN（Convolutional Neural Networks）模型的输出都是只考虑前一个输入的影响而不考虑其它时刻输入的影响，但对开放性主观题自动评分需要模型拥有联系上下文的能力。因此我们采用RNN（Recurrent Neural Network）循环神经网络模型，而传统的RNN循环神经网络虽然能够对前面的信息进行记忆并应用于当前输出的计算中，但存在长序列依赖问题和梯度消失问题，从而降低了训练的效果。而LSTM神经网络模型作为一种特殊的（RNN）循环神经网络模型，其增加了输入门、输出门、忘记门三个控制单元，随着信息进入该模型，LSTM中的单元（cell）会对该信息进行判断，符合规则的信息会被留下，不符合的信息会被遗忘。经过我们的调查，不少研究表明，LSTM循环神经网络能够有效的解决传统的循环神经网络（RNN）模型的长序列依赖和梯度消失梯度爆炸问题。因此我们选用LSTM循环神经网络。基于LSTM的递归神经网络模型的结构如图所示：

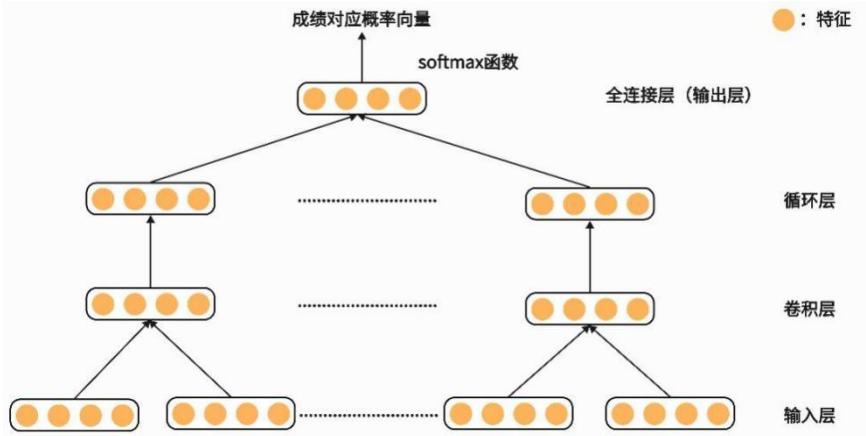


图3-2 基于LSTM的递归神经网络模型的结构

如图所示，我们的循环神经网络由输入层、卷积层（Convolution layer）、循环层（Recurrent Layer）、Dropout层、Dense层（全连接层作为输出层）组成。其具体运作过程和作用分为如下几个部分：一、输入层。我们用bert-base-chinese预训练语言模型获得学生答案文本的张量表示之后，将文本的张量表示经过一系列降维处理后作为神经网络的输入。二、卷积层（Convolution layer）。卷积层的作用是观察输入的文本并提取输入文本中的局部特征。卷积层的激活函数是ReLU函数。三、循环层（Recurrent Layer）。我们的循环层采用的是LSTM（Long Short-Term Memory）循环神经网络模型。循环层的作用是处理输入的特征。四、Dropout层。其设置目的

是防止训练模型对训练数据集的过度拟合化。五、Dense层（全连接层）。作为神经网络的输出层，全连接层的输出函数使用 softmax 函数输出概率向量，每个分量均落在 0~1 的区间中，且每个分量相加和为1。由此计算出六个成绩等级（A、B、C、D、E、F）的对应概率，即为：

$$\text{softmax}(\theta_h(x))_i = \frac{e^{\theta_h(x)_i}}{\sum_j^n e^{\theta_h(x)_j}}$$

为提高训练的效果，我们使用keras库中的compile函数对训练过程进行编译。分为以下两个部分：

考虑到本研究采用有监督的方式训练主观题自动阅卷模型，我们采用设置损失函数的方式来表现预测值与损失函数的差距，衡量模型预测的好坏，并调整模型参数，提高模型预测准确度。在自动阅卷模型中，我们用categorical_crossentropy作为训练模型的损失函数，函数的公式如下：

$$\text{Loss} = - \sum_{i=1}^{\text{output size}} y_i \cdot \log \hat{y}_i$$

通过上述操作，我们已经设置了损失函数并衡量了模型的好坏。我们将定义优化器Adam，目的是更新和计算影响模型训练和模型输出的网络参数，使其逼近或达到最优值，从而最小化损失函数值，优化模型。

③. 成绩计算函数

在LSTM循环神经网络模型的softmax函数分别输出了六个成绩等级（A、B、C、D、E、F）的概率后，我们不是直接用最大概率作为模型预测的结果，而是将自定义一个成绩计算函数，根据softmax函数输出的六个成绩等级对应的概率计算学生最终的成绩。在自动阅卷模型的训练阶段，训练数据集的标签以及模型的输出均为成绩等级（A、B、C、D、E、F）的形式，考虑到使用成绩等级的方式太过于僵硬，且无法更好的使用成绩来区分学生之间的差距。因此，我们将调整模型的输出为百分制的形式，调整方案如下：

Step1:避免评分分值的僵硬化，将成绩转换为百分制：六个成绩等级 A、B、C、D、E、F 分别对应六个分数值100、85、70、55、40、25。

Step2:模型输出时存在极小概率但对应较大分值的情况，考虑到这个情况对模型进行加权评分时影响较大，因此在LSTM循环神经网络模型的 softmax 函数输出六个成绩等级对应的六个概率后，去除概率值小于5%的项。

Step3:模型输出概率值相等或者极为接近的情况已经被查询器所保留。

Step4:去除概率值小于5%的项后，若剩余概率值中的最大值大于70%，则以最大概率值对应的成绩等级的分数值作为模型的输出（学生成绩）。

Step5:若剩余概率值中的最大值小于70%，则模型输出（学生成绩）为成绩的加权平均值，权重为概率值（六个成绩等级分数值分别乘以对应概率后，求这六个值的平均值）。

2、基于大模型的P-Tuning技术

在自动评分任务的背景下，P-Tuning (Prompt Tuning) 微调通过利用具有固定隐藏层大小 h 和词汇大小 V 的预训练语言模型 G ，以精准预测学生答案的分数。这一过程涉及到引入标记数据集 D ，包括一系列学生答案 x_i 及其相应分数 y_i 组成的元组 $\{(x_i, y_i)\}_{i=1}^N$ ，其中 N 表示样本总量。P-Tuning的关键在于采用一组可训练的连续提示嵌入 $P = \{p_1, p_2, \dots, p_M\}$ ，这些嵌入直接映射到模型的输入空间，以增强模型对特定任务的认识。为实现这一目标，设计了特定任务的提示模板 T ，形式为“学生答案为： $INPUT$ ，预测分数为： $MASK$ ”，其中 $MASK$ 是模型需要填充的部分。模板 T 指导将学生答案 x_i 和预期输出 y_i 格式化为输入形式。

接着，将这些连续提示嵌入与学生答案文本 x_i 在嵌入空间中进行拼接，形成增强模型输入 $\text{增强输入} = [T; x_i] = [p_1; p_2; \dots; p_M; x_i]$ 。然后，映射函数 f ，结合LSTM和MLP，将拼接后的输入转化为模型可处理的形式 $\text{模型输入} = f([T; x_i]) = f([p_1; p_2; \dots; p_M; x_i])$ 。映射函

数 f ，通过MLP和LSTM的结构优化了连续提示嵌入的表达，使模板 T 与学生答案的组合能够被模型有效地理解和预测。训练的目标是最小化模型预测的分数与实际分数之间

的损失，采用均方误差 (MSE) 作为损失函数 $L = \frac{1}{N} \sum_{i=1}^N (G(f([T; x_i])) - y_i)^2$ ，这里 $G(\cdot)$

代表经过提示嵌入和映射函数处理后，预训练模型 G 的预测输出。此方法不仅利用预训练模型 G 的强大语言表征能力，通过精确调整连续提示嵌入 P 适应自动评分任务，提高预测分数的准确性，同时保持模型的泛化能力，在降低训练成本的同时提升模型性能。完成训练后，模型 G 的输出用作学生答案的预测分数，这个输出可以直接用来评估新的学生答案。

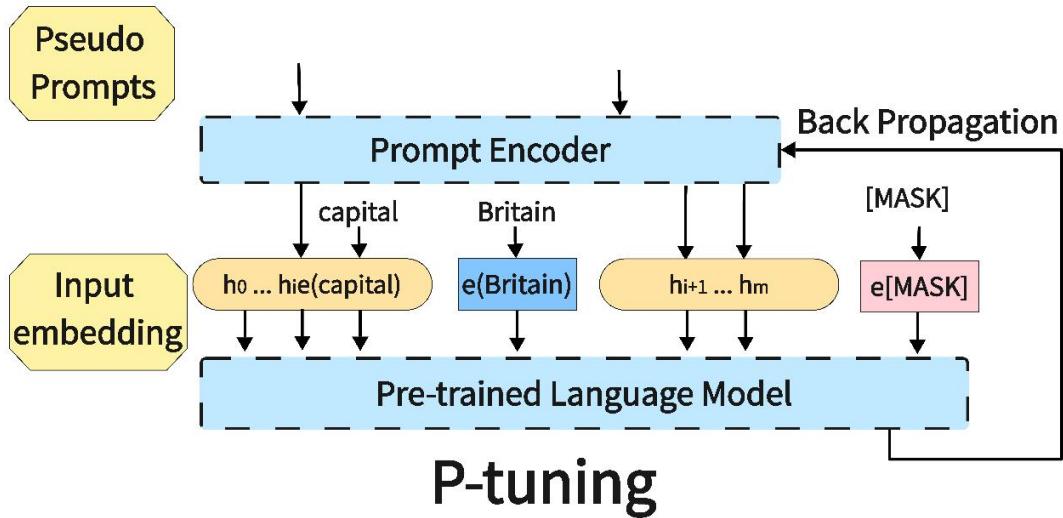


图3-3 P-tuning微调原理

3、自动阅卷评分模型的Bagging实现

自动阅卷评分模型的Bagging实现通过结合LSTM网络和微调后的大语言模型，实现对学生答案的精确评分。在Bagging框架下，首先利用自助采样法从原始训练数据集有放回地抽取多次，形成多个训练子集，每个子集保持与原始数据集相同的大小。对每个子集，分别训练一个LSTM模型和一个微调后的大语言模型，分别利用他们捕捉文本序列长距离依赖和理解复杂语言上下文。通过这种方式，为每个子集生成两个预测结果，一个来自LSTM模型，另一个来自微调后的大语言模型。然后，对于给定的输入答案，每对模型针对同一数据点的预测结果被平均处理，以此作为该数据点的评分预测。最终，通过集成所有训练子集上的模型预测，作为该数据点的最终评分。这种方法充分利用了模型平均减少预测方差的优点，提高了评分的准确性和模型的泛化能力。

4、实验运行环境和参数配置

所有模型均在配置为NVIDIA RTX A6000显卡（48 GB GDDR6显存）的计算机上进行训练和测试。计算机操作系统为Ubuntu 22.04.2 LTS (Jammy Jellyfish)，CUDA版本为12.2，驱动版本为535.104.05。

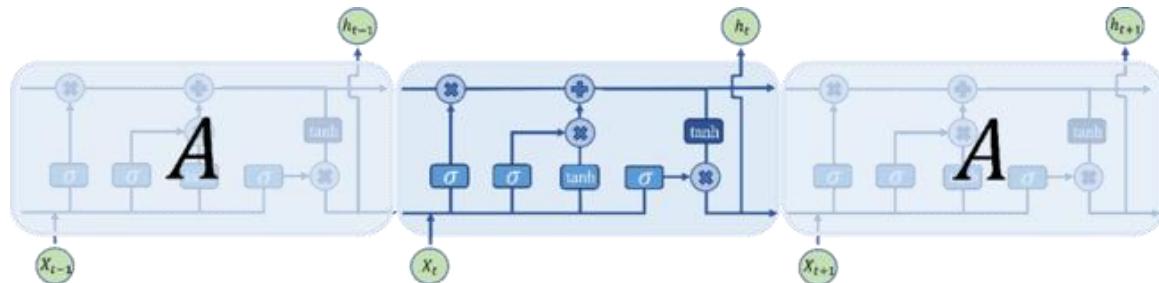


图3-2-5 LSTM架构图

表3-2-1：LSTM的参数配置

优化器	学习率	损失函数	训练轮数	批尺寸
Adam	0.45	MAE	1000	35

对于大模型，我们选用**ChatGLM2-6B**。ChatGLM2-6B 是由清华大学研发团队开发的自然语言处理模型，基于 Transformer 架构，拥有 6.7 亿参数，专为文本分类、情感分析、问答系统和文本生成等任务设计。相比初代模型，ChatGLM2-6B 在多个数据集上的表现显著提升，确保了自动阅卷评分过程中的高准确度和一致性。通过 FlashAttention 技术，该模型的上下文长度扩展到 32K，并在对话阶段使用 8K 上下文长度进行训练，能够更好地处理学生的长文本答案。基于 Multi-Query Attention 技术，推理速度提高了 42%，显存占用大幅降低，使得大规模自动阅卷更加可行和经济。



图3-2-6 大模型选型

PTuning技术通过添加少量的提示信息，优化预训练大模型，使其更好地适应具体的评分任务。这种微调方法不仅提高了模型的准确性和一致性，还显著提升了评分效率。在模型训练与微调过程中，我们精心设计了参数设置，如预处理长度、学习率、梯度累积步数等，确保模型能够高效学习和处理短问答评分任务。

表3-2-2 P-tuning微调的参数配置

PRE_SEQ_LEN	NUM_G_PUS	gradient_accumulation_steps	max_step_size	max_source_length	max_target_length
128	1	16	3000	64	128

5、结果

模型预测的预测值与真实值的对比图如下所示：

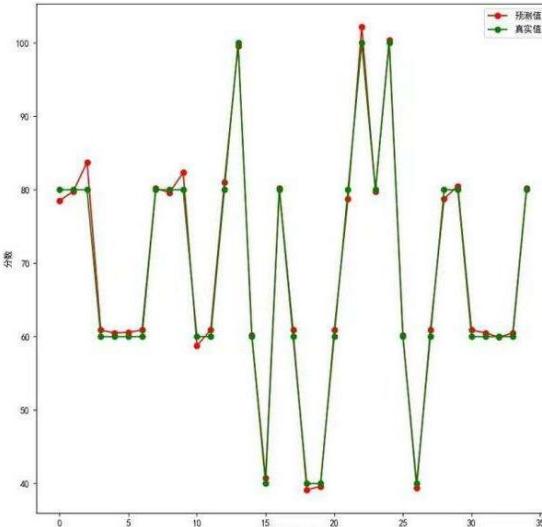


图3-2-7预测值-真实值对比图

通过引入了LSTM 和大模型 p-Tuning 微调技术，显著提升了自动阅卷评分的效率和准确性，实现了高达 **82.13%**的准确率。综上所述，通过结合LSTM(长短期记忆网络)与基于大模型的 P-Tuning(提示微调)技术，我们构建了一种高效且准确的自动阅卷评分方法。

3.2.2 基于大模型知识追踪的学习者模型

1、问题定义

知识追踪 (Knowledge Tracing, KT) 问题主要关注的是跟踪学生知识状态随时间变化的任务。形式化地，给定学生的历史学习交互序列 $I_t = (I_1, I_2, \dots, I_n)$ ，其中每个交互 I_t 包括题目 e_i ，学生的作答情况 $r_i \in \{0,1\}$ (其中1表示正确答案)，作答所用时间 dt_i ，以及其他相关信息 o_i 如时间戳、练习类型等。知识追踪的目标是预测学生在下一个交互 $I_{\{n+1\}}$ 中正确回答问题的概率。

$$p(r_{\{n+1\}}=1 | I_t) = \sigma(f(\theta, e_{\{n+1\}}, o_{\{n+1\}}, dt_{\{n+1\}}, St))$$

在本项目中，我们主要聚焦在使用大模型在预训练和微调范式下预测下一次交互中的正确回答问题的概率，为此我们基于基于 PromptCast 范式，结合Neshaei的研究开发出基于知识追踪的KTPromptCast，将数值历史观测值转换为自然语言句子，而不是使用数字序列。在 Neshaei的研究中，模型已经具备了初步的性能，但是由于提示中包含的信息较少可能影响模型表现。本项目将在提示中加入不同的特征以及采用链式思考提示策略，帮助模型准确推理学生表现。



Question	1	2	3	4	5	6	7
Skill ID	2	3	1	1	2	1	3
Answer	✓	✗	✓	✓	✗	✗	?

图3-2-8知识追踪原理图

2、 KTPromptCast开发

本项目初步开发了下面三种不同的 Prompt

表3-2-3 三种不同的 Prompt

PromptA	<p>Prompt:</p> <p>Current skill ID:2</p> <p>Total correct for prior questions with skill ID 2:2 Total wrong for prior questions with skill ID 2:1 Total correct until now:6</p> <p>Total wrong until now:4</p> <p>Current question ID:1 1</p> <p>Student response:</p> <p>Completion: correct or wrong</p>
PromptB	<p>Prompt:</p> <p>Given the student's performance data:</p> <p>Current skill ID: [Insert skill ID]</p> <p>Total correct answers for prior questions with skill ID [Insert skill ID]: [Insert total correct for the skill]</p> <p>Total wrong answers for prior questions with skill ID [Insert skill ID]: [Insert total wrong for the skill]</p> <p>Total correct answers across all skills until now: [Insert total correct across all skills]</p> <p>Total wrong answers across all skills until now: [Insert total wrong across all skills]</p> <p>Current question ID: [Insert current question ID]</p> <p>k-most recent responses across all questions: [List the k-most recent responses]</p> <p>k-most recent responses related to specific skill ID [Insert skill ID]: [List the k-most recent responses for the skill]</p> <p>Predict whether the student's response to the current question is likely to be correct or wrong based on the above historical performance information and the context of the current question.</p> <p>Completion: correct or wrong</p>
PromptC	<p>Prompt:</p> <p>Identify Current Question Context</p>

	<p>Skill ID: [Insert skill ID]</p> <p>Question ID: [Insert current question ID]</p> <p>Review Historical Performance for the Specific Skill Total Correct Answers: [Insert total correct for the skill] Total Wrong Answers: [Insert total wrong for the skill]</p> <p>Most Recent 3 Responses for the Skill: [List the 3-most recent responses for the skill]</p> <p>Analyze Overall Historical Performance Across All Skills Total Correct Answers: [Insert total correct across all skills] Total Wrong Answers: [Insert total wrong across all skills]</p> <p>Most Recent 3 Responses Across All Questions: [List the 3-most recent responses]</p> <p>Prediction Decision</p> <p>Based on the compiled data above and considering the specific skill and overall performance, predict whether the response to the current question will likely be correct or incorrect.</p> <p>Completion: correct or wrong</p>
--	--

3、模型训练

首先进行数据预处理，将收集到的时间序列数据根据设计的Prompt转换为文本，然后通过训练好的大模型进行训练和微调，根据模型输出的预测结果，分析学生的知识掌握状况和潜在学习困难。通过对准确率、召回率和F1分数等评估指标探索不同Prompt设计，实现特定领域的大模型时序预测任务。

在这一框架下，DKT的实现不再依赖于传统的递归神经网络或长短期记忆网络模型的复杂架构，而是通过语言模型强大的自然语言处理能力来捕捉学生做题序列中的模式和关系。这种方法的优势在于它允许直接从数据中学习知识状态的潜在表示，而无需预设复杂的模型架构，同时也能够灵活处理各种形式的做题记录数据。不仅解决了传统方法中存在的冷启动问题，而且通过动态追踪学生的知识状态，支持更加个性化和精准的学习路径设计。

4、模型评估

通过实验对比，我们选择效果更好的PromptC进行实验。我们采用 PromptC，将 ASSISTments 2009 dataset 的数据进行相应的预处理。

表3-2-4 ASSISTments 2009 数据集

ASSISTments 2009 数据集	使用 ASSISTments 系统收集的数据编译而成。它包含 17708 个独特的问题和 3114 个独特的用户。在所有记录中，65.9%
----------------------	---

(183303 个) 得到了正确回答, 其余的 (95033 个) 回答错误。

预处理后采用 chatglm2-6b 进行微调训练。训练细节如下：

```
PRE_SEQ_LEN=128
LR=1e-3
NUM_GPUS=1

torchrun --standalone --nnodes=1 --nproc-per-node=$NUM_GPUS main.py
  --do_train \
  --train_file train_prompts_and_responses.json \
  --preprocessing_num_workers 10 \
  --prompt_column prompt \
  --response_column actual_response \
  --overwrite_cache \
  --model_name_or_path ../../chatglm2-6b \
  --output_dir output/zsz-chatglm2-6b-pt-$PRE_SEQ_LEN-$LR \
  --overwrite_output_dir \
  --max_source_length 64 \
  --max_target_length 128 \
  --per_device_train_batch_size 1 \
  --per_device_eval_batch_size 1 \
  --gradient_accumulation_steps 16 \
  --predict_with_generate \
  --logging_steps 10 \
  --save_steps 1000 \
  --learning_rate $LR \
  --pre_seq_len $PRE_SEQ_LEN \
  --max_steps 3000 \
  --save_safetensors False \
  --warmup_ratio 0.1 \
  --weight_decay 0.001 \
  --fp16 True \
```

图3-2-9：模型训练参数

```
{"labels": "correct", "predict": "correct"
{"labels": "correct", "predict": "wrong"}
 {"labels": "correct", "predict": "correct"
 {"labels": "correct", "predict": "correct"
 {"labels": "wrong", "predict": "wrong"}
 {"labels": "correct", "predict": "correct"
 {"labels": "correct", "predict": "correct"
 {"labels": "correct", "predict": "correct"
 {"labels": "wrong", "predict": "wrong"}
 {"labels": "correct", "predict": "correct"
 {"labels": "correct", "predict": "correct"
 {"labels": "wrong", "predict": "wrong"}
 {"labels": "wrong", "predict": "wrong"}
```

图3-2-10: 模型训练结果 (前几行)

模型评估结果：

表3-2-5 模型评估结果

Model	AUC	F1	RMSE	Acc	Bal Acc	Precision	Recall
基线: LLM(Neshaei FT Ext)	0.71	0.81	0.46	0.70	0.56	0.69	0.98
BKT	0.71	0.80	0.44	0.71	0.62	0.73	0.88
Best-Lr	0.76	0.81	0.42	0.73	0.66	0.75	0.88
DKT	0.75	0.81	0.43	0.73	0.66	0.76	0.87
SAKT	0.72	0.78	0.45	0.70	0.65	0.75	0.81
KTPrompt (PromptC)	0.77	0.82	0.45	0.80	0.70	0.78	0.85

KTPrompt模型在各项指标上均表现出色，展示了其作为知识追踪工具的可靠性和精确性。与其他模型相比，KTPrompt在准确率、平衡准确率和精确率方面均有显著优势，特别是在平衡处理类别不平衡数据和提高预测正样本准确性上表现突出。虽然模型的召回率略低于一些高召回率模型，但仍然保持在较高水平，综合性能优异。整体而言，KTPrompt模型以其均衡的性能、较高的准确性和精确性，以及良好的误差控制，成为知识追踪的理想选择，能够为用户提供可靠和精确的追踪结果。

3.2.3 基于联邦学习的教育—就业匹配模型

当前的教育和职业培训领域面临着一个关键挑战，即匹配学习内容与市场岗位需求的精确度。传统教育体系常常无法迅速适应企业对专业技能和知识的最新需求，导致教育资源的浪费和学习效率的下降，并加剧了毕业生的就业难题。企业在招聘过程中难以找到符合其具体需求的人才，教育机构也在努力调整课程内容，希望能更好地满足学生的就业前景。针对这些挑战，我们引入了一种创新解决方案——基于纵向联邦学习和BERT的教育—就业匹配模型。

1、联邦学习框架—FATE(federated AI Technology Enabler)

一个开源的联邦学习框架，支持多种计算场景下的隐私保护和数据安全。FATE(Federated AI Technology Enabler)是微众银行AI部门发起的全球首个联邦学习工业级开源框架，可以让企业和机构在保护数据安全和数据隐私的前提下进行数据协作。FATE项目使用多方安全计算(MPC)以及同态加密(HE)技术构建底层安全计算协议，以此支持不同种类的机器学习的安全计算，包括逻辑回归、基于树的算法、深度学习和迁移学习等。在本模块中，FATE用于在不同参与方之间安全地协调数据和模型训练过程。

2、纵向联邦学习(Vertical Federated Learning)

纵向联邦学习(Vertical Federated Learning)是一种高度隐私保护的机器学习方法，旨在解决不同参与方拥有相同样本空间但特征空间不同的情况下的数据共享和模型训练问题。在纵向联邦学习中，参与方可以是不同组织、企业或个人，它们之间通过共享样本数据来进行模型训练，而无需将原始数据传输到中心服务器或第三方平台。纵向联邦学习的基本原理是通过加密和安全计算技术，在保护数据隐私的前提下，实现参与方之间的模型训练和信息交换。首先，参与方需要对数据进行加密或扰动，然后使用加密后的数据进行模型训练和信息交换。在模型训练过程中，参与方共享的信息仅限于模型参数更新，而不涉及原始数据的传输或共享，从而确保了数据隐私和安全性。

3、技术实现

根据最近发展区理论(ZPD)，学习内容的难度应略高于学生当前的能力水平，使学生在学习过程中既不会感到无聊也不会失去信心。与传统机器学习方法相比，纵向联邦学习使不同组织能够在不共享原始数据的情况下共同训练模型。通过这种方法，我们可以在保障数据隐私和安全的同时，有效整合教育机构和企业的数据，构建能够预测课程内容与岗位需求匹配度的模型。结合纵向联邦学习和自然语言处理技术，通过分析和预测课程内容与岗位需求的匹配程度，支持教育质量的提升和就业率的增长。系统架构包括学校端、企业端和联邦学习平台，分别负责提供课程数据、岗位数据以及协调数据交互和模型训练。数据预处理利用BERT模型进行文本特征提取，并通过PCA降维提高模型训练效率。模型训练采用联邦异构神经网络(Hetero NN)，允许多个参

与方在保持数据隐私的前提下，共同进行模型学习。通过这一创新解决方案，我们不仅提升了教育内容的实用性和就业率，还为构建智能的职业教育桥梁提供了技术支持，实现了教育资源的最优配置和人才培养的最大化效益。

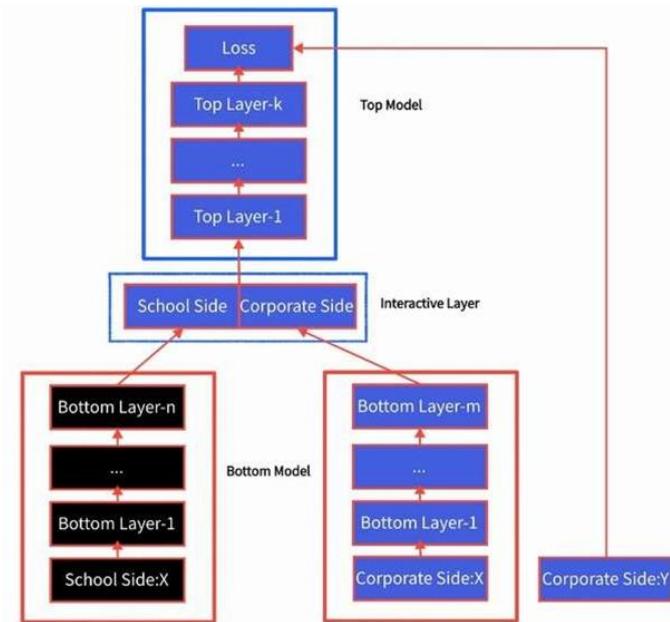


图3-2-11: 异构神经网络模型架构图

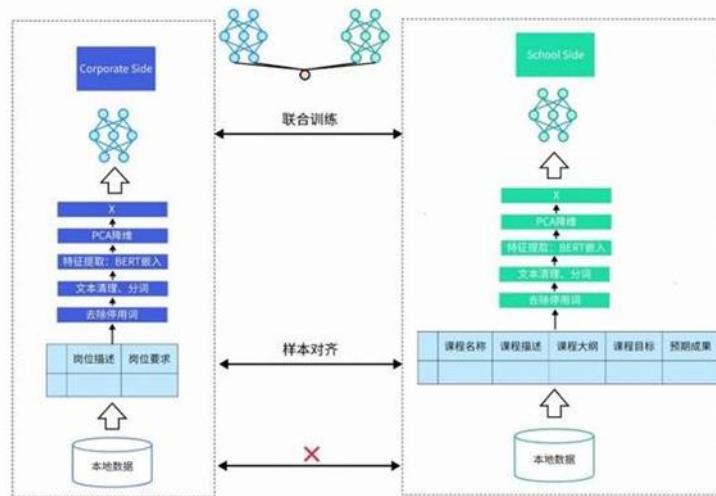


图3-2-12: 纵向联邦学习架构图

4、模型评估

在本项目的模型评估阶段，我们采用了一系列综合性的评价指标来全面衡量模型的性能和效果。关键评估指标包括平均ROC AUC得分(One-vs-All)、精确率(Precision)、召回率(Recall)、F1得分(F1-Score)、准确率(Accuracy)以及PR曲线下面积(PR Curve AUC)。以下是我们所获得的测试结果：

表3-2-6 模型评估结果

指标名称	值
Average ROC AUC Score (One-vs-All)	0.827
One-vs-All ROC AUC Score	0.827
Precision	0.769
Recall	0.763
F1-Score	0.766
Accuracy	0.772
PR Curve AUC	0.785

这些结果表明，我们的模型在预测课程内容与岗位需求匹配度方面具有较高的准确性和可靠性。特别是平均ROC AUC得分达到0.827，显示了模型具有很好的区分正负样本的能力。精确率和召回率的平衡表现在F1得分中，达到了0.766，这意味着模型在保持较高召回率的同时也具有较高的精确度。准确率为0.772，进一步证实了模型的整体性能表现。PR曲线下面积为0.785，表明在不同的阈值下，模型对正类的预测具有较高的可靠性。

通过这种解决方案，教育机构和企业可以在一个共享的生态系统中合作，共同培育和优化学习路径。这种协作将教育者、学习者以及行业专家连接起来，为每个人创造一个共同成长和进步的平台。我们的目标是推动教育内容与职业市场需求之间的紧密对接，实现教育资源的最优配置和人才培养的最大化效益，构筑起一个智能的职业教育桥梁。这一解决方案不仅提高了教育质量和就业率，更推动了教育与职业市场之间的协调一致，体现了我们对提升教育和职业培训效率的坚定承诺。

3.3 用户接口层

3.3.1 基于大模型RLHF生成多样范式

在建构主义教育理论框架下，学习被视为学生通过与知识和现实世界的互动主动构建自己的理解的过程。因此通过 RLHF（Reinforcement Learning from Human Feedback）生成多样化和高质量的教育内容可以极大地促进学生的主动学习和理解。首先，这个过程开始于使用问答对数据集进行监督微调（SFT），这些数据集精心挑选以确保内容的教育价值和准确性。监督微调后的模型（SFT）能够生成基本的答案，这是构建有效奖励模型的基础。接下来，基于从监督微调模型生成的答案，我们构建一个奖励模型。这一阶段涉及到对模型生成的不同答案进行评分，这些评分反映了答案的质量、创新性和教育效果。通过这种人类反馈，奖励模型学习如何区分高质量答案与低质量答案，并生成相应的评分（reward scores），用于模型优化。最后，通过近端策略优化（PPO）技术进一步微调 SFT 模型。在这一阶段，PPO 利用从奖励模型

得到的反馈来优化语言模型，使其产生的答案更符合人类教育专家的偏好。通过反复迭代，模型学习生成更精确、更具创造性且多样化的答案，从而能够更好地服务于教育目的。

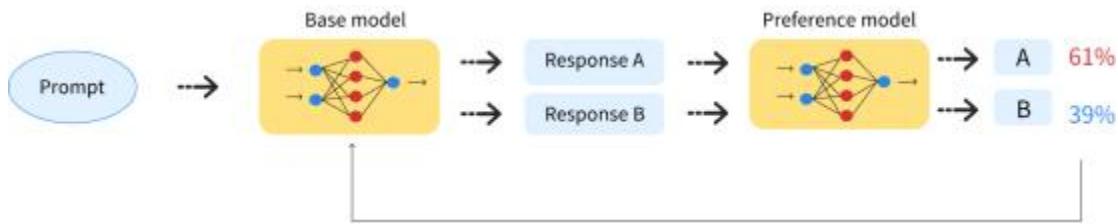


图3-2-13: RM模型训练过程



图3-2-14: 个性化题目解释反馈流程图

3.3.2 基于协同过滤算法的个性化题目推荐

基于教育心理学中的建构主义理论，我们利用协同过滤算法进行个性化的题目推荐。根据建构主义理论，学生通过与环境和内容的互动，主动构建知识体系。因此，推荐题目的难度非常关键：太简单的内容会让学生觉得无趣，而太难的内容则会使学生丧失信心。因此，推荐的题目应稍高于学生当前水平，确保学生在一定时间学习后能达到目标，并感受到成就感，从而提升学习兴趣。我们整合了基于物品和基于用户的协同过滤算法，形成一个高效的个性化推荐模块。该模块致力于通过精准推荐，帮助用户掌握特定知识点，并通过分析用户间的相似性，推荐能激发学习兴趣的新题目，增强学习的积极性和主动性。用户可以自定义推荐题目的过滤条件，如年级水平、学科内容和主题话题，从而获得真正符合个人偏好和需求的定制化题目推荐。基于物品的协同过滤算法通过预算所有用户的历史偏好数据，计算题目之间的相似度，并向用户推荐与其偏好相似的题目。具体步骤包括：计算题目相似度、寻找邻居物品、生

成推荐预测和生成推荐列表。假设用户A在题目a上的得分较低，算法会识别在题目a上得分高的用户群体，计算这些用户在其他题目上的得分，并通过余弦相似度选出相似度最高的题目推荐给用户A，从而帮助其提高在该知识点上的掌握程度。基于用户的协同过滤法则利用用户间的相似性来进行推荐。通过分析用户在各个学科和技能上的练习记录，为用户推荐未尝试过的、可能提升其学习兴趣的题目。假设用户A与用户B在某些题目上的做题频率和得分行为相似，那么用户A可能会对用户B擅长做的其他题目感兴趣。具体步骤包括计算用户间相似度、生成推荐列表等。结合用户行为数据和偏好设置，确保每位用户都能在其学习旅程中发现最适合、最有挑战性的内容。这种深度个性化的方法，不仅提高了学习效率，还提升了学习过程的乐趣和深度。通过这个模块，我们期待为用户打造一个更加富有成效和吸引力的学习环境，促进知识的深入理解与应用，推动教育质量和学习体验的个性化提升。

a. 基于物品的协同过滤算法

此算法的核心思想是基于所有用户的历史偏好数据预算算物品(本场景中为题目)之间的相似度，进而向用户推荐与其偏好相似的题目。在提升用户学习能力的应用场景中，算法逻辑如下：假设用户A在题目a上的得分较低，表明用户A在这一知识点上有提升空间。算法首先识别在题目a上得分高的用户群体(称为“优秀用户”)，假定他们在该知识点表现优秀是因为他们练习了特定的相关题目。接下来，通过计算这些相关题目之间的相似度，选出相似度得分最高的题目推荐给用户A，从而帮助用户A提高在该知识点上的掌握程度。在此过程中，我们将在题目a上表现不佳的用户A称为“目标用户”。

Step1：计算题目相似度

基于上述逻辑，我们首先通过数据库筛选出所有优秀用户，遍历优秀用户在其他题目上的得分，筛选出与指定题目类型相同且难度(在此数据集中为年级)相近的题目，并且选择那些得分高于75%分位数的用户记录，以便后续构建物品相似度矩阵。随后，我们根据训练数据构建物品共现矩阵，即记录每两个题目被同一个用户共同作答的次数。基于此共现矩阵，我们使用余弦相似度作为相似度的度量标准，算法如下：

$$\text{similarity}(A, B) = \frac{\sum_{u \in U} R_{u,A} \cdot R_{u,B}}{\sqrt{\sum_{u \in U} R_{u,A}^2} \cdot \sqrt{\sum_{u \in U} R_{u,B}^2}}$$

其中，

- U 是同时做过题目A和题目B的得分集合。
- $R_{u,A}$ 和 $R_{u,B}$ 分别是用户u在题目A和题目B上的得分

Step2：寻找邻居物品

在基于物品的协同过滤算法中，寻找邻居物品是通过评估物品之间的相似度来实现的。这一步骤的目的是为每个用户已交互过的题目找到一组“邻居物品”，即那些

与用户已解决题目相似度最高的其他题目。

根据目标用户 u 已经解决的每个题目 i , 从相似度矩阵中获取与题目 i 相关的所有相似度数据。这些数据反映了题目 i 与数据集中其他所有题目之间的相似度。然后, 根据题目 i 与其他题目的相似度得分, 选择相似度最高的 K 个题目作为 i 的邻居物品。由于相似度矩阵已经包含了所有必要的相似度得分, 所以此步骤不涉及新的相似度计算, 只需要从矩阵中检索并排序即可。

在选择邻居物品时, 我们忽略那些用户 u 已经解决过的题目, 以确保推荐列表的新颖性。剩余的题目根据它们与题目 i 的相似度得分进行排序, 选出得分最高的 K 个题目。

Step3: 生成推荐预测

在得到邻居物品之后, 我们对用户每个未交互过的题目的预测得分。此预测得分不仅映射了题目对于用户的适配程度, 而且还反映了题目对用户学习能力的潜在增强效果。具体来说, 这种预测旨在确保推荐的题目既能够符合用户的当前学习水平, 又能在不超出其舒适区的前提下, 渐进式地推进学习深度和广度。通过这样的策略, 系统旨在最大化用户的满意度和个性化体验, 同时避免让用户面对过于挑战性的内容, 从而减少可能的挫败感和学习动力的损失。这种方法细腻地平衡了推荐内容的难度与用户的现有知识水平, 旨在提供一个充满挑战但又不至于令人气馁的学习路径, 进而激发和保持用户的学习兴趣。

在初始阶段, 对于目标用户 u , 系统初始化一个空集合用于累积每个可能的推荐题目及其预测得分, 确保推荐的准确性与适应性。随后, 算法遍历用户 u 已解决的每个题目 i , 对于每个 i , 找到其 K 个最相似的邻居物品。对于每个邻居物品 j , 如果 j 未被用户 u 解决过, 则其对用户 u 的推荐得分(即预测兴趣评分)将根据下面的公式累加计算:

$$score(u, j) = \sum_{i \in I(u)} sim(i, j)$$

其中,

- $score(u, j)$ 表示目标用户 u 对题目 j 的预测兴趣评分
- $sim(i, j)$ 是题目 i 与 j 之间的相似度分数。

这种方式下, 如果一个题目 j 与用户 u 已解决的多个题目相似, 则它会得到一个较高的预测得分, 反映了该题目与用户现有知识和偏好的匹配度。

Step4: 生成推荐列表

通过以上步骤, 算法最终为每位用户生成了一个根据预测兴趣评分排序的推荐题目列表, 从中选取得分最高的3个题目形成最终的推荐列表。这种方法能够有效地挖掘和利用用户的偏好信息, 为他们提供个性化的题目推荐, 从而在一定程度上提高用

户的学习效率和学习成果。

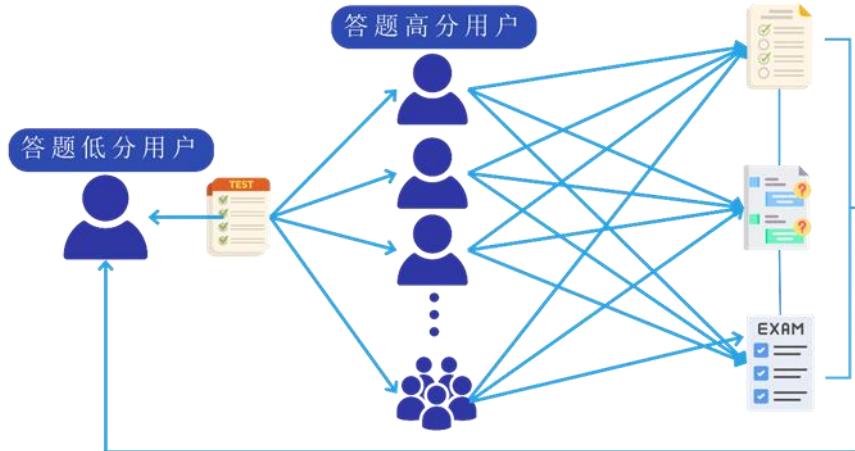


图3-2-15基于物品的协同过滤算法

b. 基于用户的协同过滤算法

该算法的核心思想是利用用户间的相似性来进行推荐。本算法通过分析用户在各个学科和技能上的练习记录，为用户推荐未尝试过的、可能提升其学习兴趣的题目。我们假设如果用户A与用户B在过去对某些题目上做题的频率和得分行为上很相似，那么用户A可能会对用户B擅长做的其他题目也感兴趣，反之亦然。

该算法具体实现方法与基于物品的协同过滤算法类似，在此只说明不同点，不进行赘述。

Step 1：计算用户间相似度

首先，遍历用户记录，为每位用户在各个维度（学科、主题、类别、技能点、任务类型和年级）上建立偏好模型。模型以字典形式存储，记录了用户在各个维度上尝试的题目数量及正确的题目数量。使用余弦相似度作为相似度度量。

假设用户 u_i 在维度 d 的偏好向量为 $\mathbf{P}_{u_i,d}$ ，用户 u_j 在维度 d 上的偏好向量为 $\mathbf{P}_{u_j,d}$ 。

余弦相似度的计算公式为：

$$\text{similarity}(u_i, u_j) = \cos(\mathbf{P}_{u_i,d}, \mathbf{P}_{u_j,d}) = \frac{\mathbf{P}_{u_i,d} \cdot \mathbf{P}_{u_j,d}}{\|\mathbf{P}_{u_i,d}\| \|\mathbf{P}_{u_j,d}\|}$$

其中，向量 $(\mathbf{P}_{u,d})$ 的每个元素是根据用户在该维度上的正确率乘以相应的权重计算得到的：

$$\mathbf{P}_{u,d} = [p_{u,d,1}, p_{u,d,2}, \dots, p_{u,d,n}] \quad [p_{u,d,k} = \text{accuracy}_{u,d,k} \times \text{weight}_d]$$

这里， $\text{accuracy}_{u,d,k}$ 是用户u在维度d上第k个题目的正确率， weight_d 是维度d的

权重。

Step 2: 生成推荐列表

在计算目标用户 u 与其他用户 v 的相似度之后，选出与目标用户相似度高于某阈 θ 的用户集合 S :

$$S = \{v \mid \text{similarity}(u, v) > \theta\}$$

统计这些相似用户尝试过且目标用户未尝试过的问题。假设相似用户 S 尝试过的问题集合为 Q_S ，目标用户 u 尝试过的问题集合为 Q_u ，则目标用户未尝试过的问题集合为：

$$Q_{\text{new}} = Q_S - Q_u$$

最后，根据问题的受欢迎程度（即被相似用户尝试的次数）以及目标用户的偏好调整问题的得分。假设问题 q 的受欢迎程度为 $\text{popularity}(q)$ ，目标用户的偏好为 $\text{preference}(u, q)$ ，则问题 q 的最终得分为：

$$\text{score}(q) = \alpha \cdot \text{popularity}(q) + \beta \cdot \text{preference}(u, q)$$

其中 α 和 β 是调整受欢迎程度和用户偏好影响的权重系数。根据这些得分，推荐得分最高的 k 个问题给目标用户：

$$Q_{\text{recommend}} = \{q \mid \text{score}(q) \text{ is among the top } k\}$$

通过上述过程，基于用户的协同过滤算法能够有效地利用用户间的相似性和个人的偏好信息，为用户推荐个性化的学习内容。

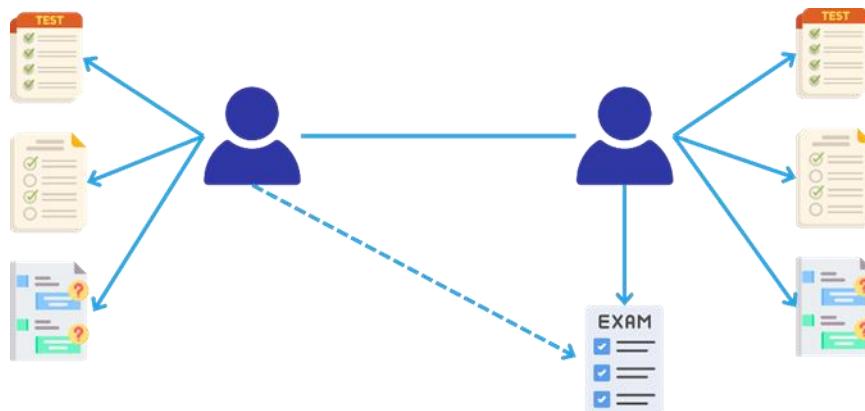


图3-2-16：基于用户的协同过滤算法

3.3.3 个性化学习导航

在现代教育领域中，构建一个动态且互联的知识图谱对于提升学习效率和教育质量具有至关重要的作用。基于建构主义教育理论，我们通过提供一个交互式的认知地图，使学生能够直观地理解自己在特定学科中的认知状态，并基于实际掌握情况提供

个性化学习建议。

建构主义教育理论强调学生主动构建知识的过程，认为学习不仅仅是接受信息，更是通过个人经验和互动来理解和形成知识的过程。通过图形化的方式展示知识点之间的关联，让学生能够清晰地看到自己的学习进度和需要重点关注的领域。

系统核心功能在于规划个性化学习路径。当学习者浏览认知地图上的知识点时，系统会实时显示学习状态，如“未掌握”或“已掌握”。对于未掌握的知识点，系统不仅会根据其前驱知识点的掌握情况，引导学习者学习必要的基础知识或加强学习，还会结合学生的学习风格和兴趣，提供个性化的学习资源和建议。这种方式真正实现了按个人节奏学习，并不断调整学习路径，推动学生主动探索和学习。

为了实现这一功能，我们采用了Neo4j图形数据库作为底层数据存储和管理工具。Neo4j以其高性能的NoSQL架构和专门设计的图形结构，能够高效地存储和查询复杂的网络数据。我们利用Neo4j的Cypher查询语言，以简洁和高效的方式编写复杂的图形查询，优化数据组织和查询性能。在构建教育领域知识图谱时，我们抽象出教育内容中的关键要素，如学科、技能、问题等，以及它们之间的关系，如技能的先决条件、问题与技能的关联等，从而结构化地表示教育资源的复杂关系。

在后端，我们使用Python语言，并通过Neo4j的Python驱动程序与数据库进行交互。Python的丰富生态系统和强大的数据处理能力使我们能够高效地处理和管理数据。我们借助Pandas库处理Excel和CSV文件数据，实现了数据的高效导入和处理。同时，Pyecharts工具用于生成动态和交互式图表，以直观地展示查询结果，为用户提供更好的数据可视化体验。

前端采用HTML5/CSS3/JavaScript技术栈构建，借助Ajax技术实现与后端的异步数据交换，确保用户能够快速、无缝地查询和浏览知识图谱中的内容。我们的用户界面设计注重用户体验，提供简洁直观的操作方式，使得教育机构和学习者能够更容易地组织和获取教育内容。

系统功能方面，我们实现了多种关键查询功能，包括查询所有技能、查询特定技能对应的问题、以及关键词搜索问题等。这些功能通过巧妙的Cypher查询实现，能够快速、高效地返回用户所需的数据。例如，通过查询所有技能功能，用户可以了解不同技能之间的依赖关系，从而更好地规划学习路径。而通过查询特定技能对应的问题功能，用户可以获得与某一技能直接相关的问题及其详细信息，进一步深入学习相关知识点。关键词搜索功能则使用户能够快速定位到与特定主题相关的问题，方便灵活地探索知识图谱中的内容。

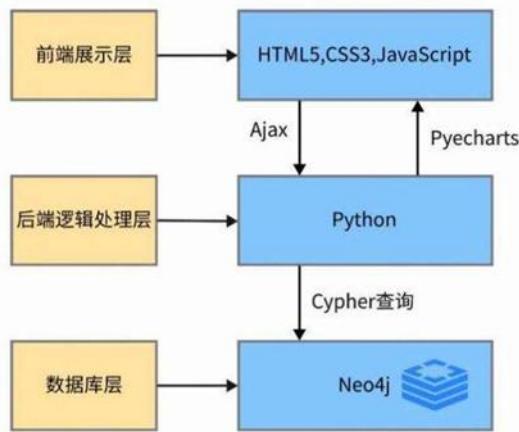


图3-2-17：知识图谱模块系统架构图

4 系统实现

4.1 系统架构

本项目的系统架构精心遵循了现代Web应用程序的分层设计原则，旨在通过精心设计的四个核心层次——展示层、通信层、服务层和数据层——显著提升系统的可扩展性、可维护性和性能。

在展示层，我们运用了包括jQuery、Vue.js在内的前端框架，以及HTML、CSS、JavaScript等标准Web技术，结合AntV等数据可视化库，为用户提供了直观、吸引人且操作流畅的用户界面（UI）和用户体验（UX）。

通信层方面，我们选择了NGINX服务器作为反向代理，通过优化请求处理流程，确保用户请求的高效转发和处理。同时，我们采用了Spring Boot框架的Controller模块，以标准化的方式处理前后端通信，确保了通信的可靠性和高效性。

服务层作为系统的核心，承载了所有的核心业务逻辑。我们设计了多个服务组件，每个组件负责特定的业务功能，以实现高内聚、低耦合的模块化设计。同时，为了提升数据处理速度和响应能力，我们与Redis缓存系统进行了深度集成，利用缓存机制加速数据访问。

在数据层，我们采用了Mybatis Plus作为对象关系映射（ORM）工具，它简化了与MySQL数据库的交互过程，使得数据库操作更加高效和简洁。同时，我们严格遵循数据库设计的最佳实践，确保数据的持久化、管理效率、完整性和一致性。

整体而言，这种分层架构的设计使得系统各层次之间高度模块化、松耦合，为系统的后续扩展和维护提供了坚实的基础。无论是在功能扩展、性能优化还是故障排查方面，这种架构都展现出了其独特的优势。

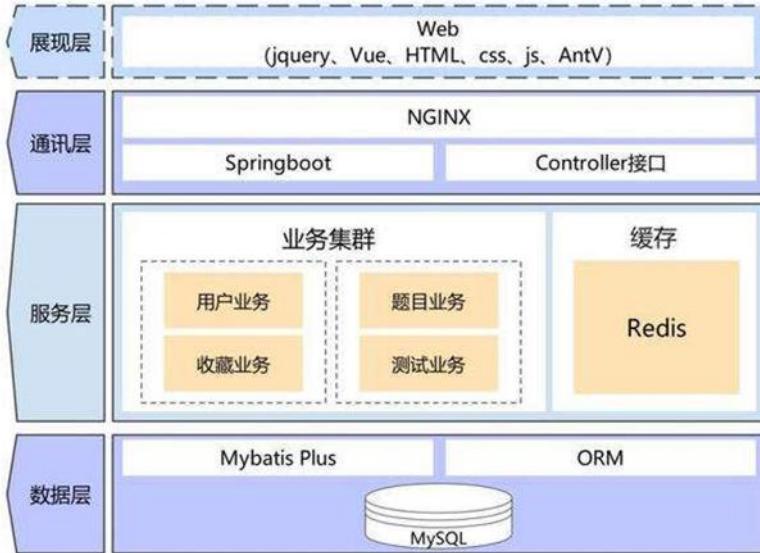


图4-1：系统架构图

4.2 技术栈

在我们的项目中，我们精心选择了一系列先进的技术栈，旨在构建一个现代化、高效且可靠的应用系统。前端技术方面，我们以HTML/CSS/JavaScript为基石，构建出富有交互性和用户友好性的Web界面。为了加速开发进程和提升界面质量，我们采纳了Vue.js框架，并辅以Element-UI这一丰富的组件库，使得UI元素的开发更加灵活和高效。同时，我们运用了Ajax技术，实现了前后端数据的异步交互，为用户带来了流畅的操作体验。

在后端架构中，我们坚定地选择了Java作为主力编程语言，并利用Spring Boot框架快速构建出健壮的基于Spring的应用程序。Spring Boot以其自动配置和约定优于配置的核心理念，极大地简化了开发流程。为了有效管理项目依赖和构建过程，我们选用了Maven作为构建工具。此外，为了提高数据访问效率和简化数据库操作，我们引入了Lombok以简化代码，MyBatis Plus作为ORM框架以简化数据库交互，以及Redis作为缓存库来优化数据读取性能。

在数据库层面，我们采用了SQL语言进行精确的数据操作，并通过JDBC作为标准接口与数据库进行交互。MySQL作为我们的主要数据库系统，负责存储用户信息、历史记录以及文本检测结果等关键数据。为了进一步优化数据库性能，我们部署了druid数据库连接池，确保在高并发场景下数据库的稳定性和响应速度。

在服务器配置上，我们选用了高性能的Nginx作为HTTP和反向代理服务器。Nginx不仅能够有效实现负载均衡和反向代理，还具备强大的静态内容缓存能力，极大地提升了网站的并发处理能力和稳定性。

在人工智能模型的研发中，我们以Python作为主要编程语言，利用PyTorch这一前沿的深度学习框架构建和训练了LSTM模型。针对中文文本的处理，我们采用了Jieba分词库进行分词操作。而在数据处理和可视化方面，我们则借助了Matplotlib、Pandas

和Scikit-learn等工具库，实现了数据的深入分析和直观展示。此外，我们还引入了Neo4j图数据库，并使用其Python驱动程序进行高效的图数据操作。



图4-2：技术栈

4.3 数据集

为了实现平台功能的全面性和准确性，我们精心集成了两个具有显著价值的数据集：ScienceQA Dataset和UNT Computer Science Short Answer Dataset。以下是这两个数据集的详细专业介绍：

(1) ScienceQA Dataset

ScienceQA Dataset是一个专注于中小学科学教育领域的多模态多项选择题数据集。该数据集共收录了21,208个问题，涵盖了丰富的科学知识点。其中，约48.7%的问题配备了图片上下文，用于直观展示科学现象或概念；48.2%的问题则提供了文本上下文，用于描述科学现象或问题背景；而30.8%的问题同时结合了图片和文本，以更全面地呈现科学问题。ScienceQA Dataset

此外，该数据集还为大多数问题提供了详细的讲座注释（占比83.9%）和解释（占比90.5%）。讲座注释为学习者提供了广泛的外部知识，帮助他们建立对科学概念的理解；而解释则具体说明了选择正确答案的理由，有助于加深学习者对科学问题的理解。

在组织结构上，ScienceQA Dataset首先按照科目（自然科学、语言科学、社会科学）进行分类。在每个科目内部，问题进一步按主题（如生物学、物理学、化学等）和类别（如植物、细胞、动物等）进行细分。最后，问题还根据技能（如分类果蔬为植物部分、识别非洲国家等）进行归类，确保学习者能够根据自己的学习需求和兴趣进行个性化学习。

通过集成ScienceQA Dataset，我们的平台能够为用户提供一个覆盖广泛学科领域、内容丰富的个性化学习体验。

(2) UNT Computer Science Short Answer Dataset

UNT Computer Science Short Answer Dataset是一个专注于计算机科学基础教

育的数据集，来源于北德克萨斯大学的入门级计算机科学课程。该数据集涵盖了10个作业和2次考试的答案，涉及多种计算机科学基础主题，如编程基础、数据结构、算法等。

每个作业包含4至7个问题，每次考试则包含10个问题。数据集不仅提供了问题和教师答案，还收录了众多学生答案，并附有两名评注者的平均分数。这些分数基于0到5的整数等级进行评分，为评估学生答案的准确性和质量提供了可靠的参考依据。

通过集成UNT Computer Science Short Answer Dataset，我们的平台能够为用户提供丰富的计算机科学学习资源，帮助他们深入理解计算机科学的基本概念和应用方法。同时，该数据集还为学生提供了自我评估和反思的机会，有助于他们不断提升自己的学习效果和能力。

4.4 数据流程

该数据流图呈现了在一个智能导学系统中学生用户数据的管理和操作流程。系统入口为学生用户身份验证，随后触发安全令牌生成机制，确保会话和交互的安全性。数据流经由多个数据处理环节，包括用户请求的处理、数据挖掘与分析，并与Redis缓存系统交互实现高效数据读写操作。

图中详细描述了数据流从入口到出口的全路径，包括用户认证、请求处理、数据聚合及报告输出模块。系统采用了模块化设计，每个蓝色矩形块象征系统中的一个功能模块，数据流向则由箭头指示，展示了各模块间的数据传递和依赖关系。

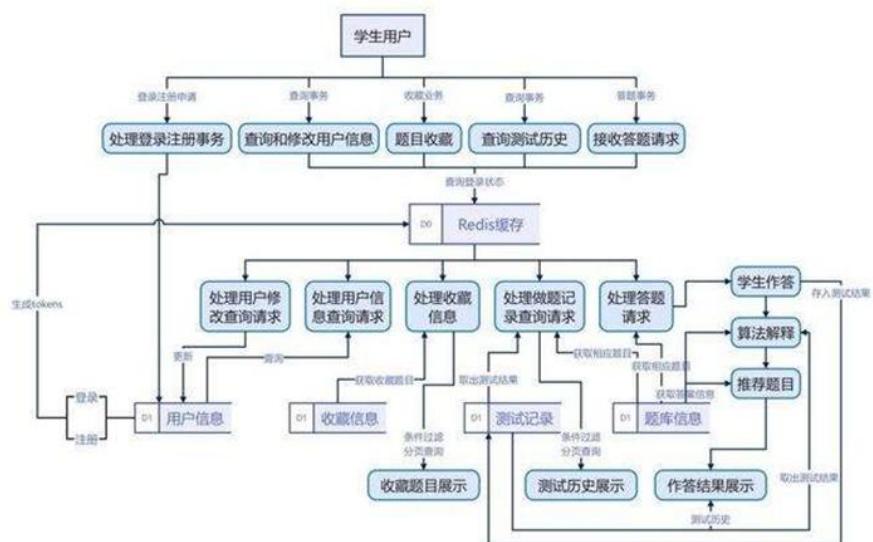


图4-3：数据流图

4.5 数据库设计

在数据库设计中，我们精心定义了三个核心实体表：user（用户）、test_result（测试结果）和problems（问题），以及两个用于支持多对多关系的关联表：favorites（收藏夹）和favorite_questions（收藏问题）。这些表通过精心设计的字段（如

`user_id`、`favorite_id`和`question_id`) 相互关联，共同构建了一个高效且功能丰富的数据模型，用于存储和查询用户信息、测试结果以及用户对问题的收藏数据。

具体来说，`user`表用于存储用户的基本信息，如用户名、密码、邮箱等。`test_result`表则记录了用户的测试结果，包括测试分数、测试时间等关键信息，并通过`user_id`字段与用户表相关联。

`problems`表用于存储问题数据，包括问题的内容、答案、选项等属性。为了支持用户收藏多个问题的需求，我们设计了一个名为`favorites`的表，用于存储用户的收藏夹信息。同时，`favorite_questions`表作为关联表，通过`favorite_id`和`question_id`字段将用户的收藏夹与具体的问题关联起来，实现了多对多的关系映射。

这种设计不仅确保了数据的完整性和一致性，还提高了数据查询的效率和灵活性。通过合理的索引设计和查询优化，我们可以快速检索用户信息、测试结果以及问题收藏数据，为用户提供更加便捷和高效的服务。

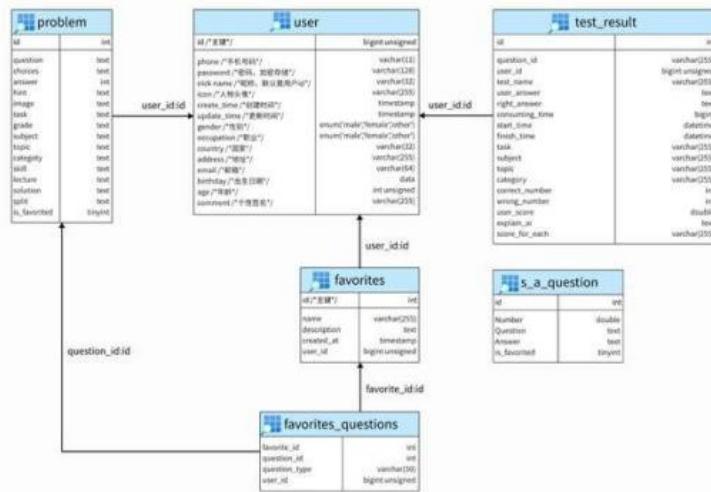


图4-4：数据库设计图

4.6 后端设计

我们的智能导学系统采用Spring Boot框架开发，构建在一个清晰的三层架构之上。系统通过RESTful API实现各组件之间的通信，核心部分如图所示：



图4-5：核心部分

4.7 平台介绍

我们为用户呈现了一个集教育规划、学习支持与职业发展于一体的智能导航平台。该平台采用先进的蓝色调，象征着智慧与冷静，结合独特的2.5D插画风格，为用户带来既专业又富有艺术感的体验。下面是平台界面的详细介绍。

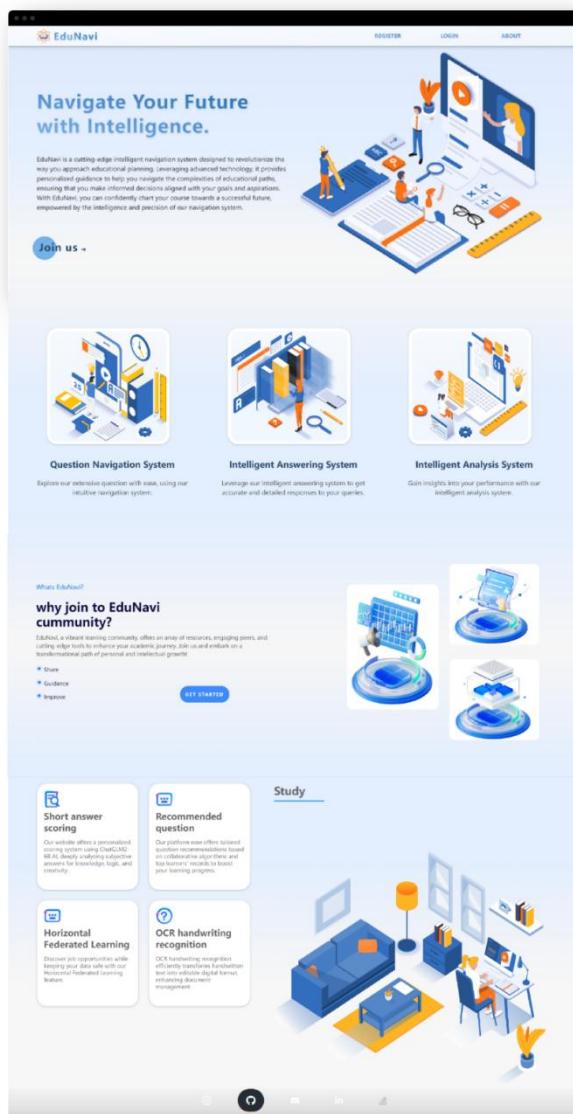


图4-6-1 首页页面

4.7.1 首页界面

在首页，我们匠心独运地设计了一个引人注目的板块，其核心标语“Navigate Your Future with Intelligence”凝聚了产品的核心理念，明确传达了我们利用智能技术助力用户规划并实现未来的愿景。这一板块在页面的显著位置，不仅凸显了学习的价值，也激发了用户对未来探索的渴望。

紧随其后的是对项目主要功能的全面概述。作为一个全方位的智源航标塔系统，

集个性化学习路径规划、前沿教育资源推荐、成绩跟踪分析以及职业发展方向预测等多项功能于一体。这些功能的精心整合，旨在为用户提供一站式的教育规划服务，帮助他们全面了解自己的学习状况和发展潜力，从而作出更明智的决策。

在页面的设计上，我们特别注重用户体验的流畅性和互动性。因此，我们巧妙地运用了直观且富有吸引力的布局，将主要功能以图形化的方式呈现给用户。同时，为了引导用户更深入地了解，我们在页面中央位置设置了醒目的“join us”按钮，用户只需轻轻一点，即可轻松注册并登录，开启他们的智能教育规划之旅。

在页面的第二个主要板块，我们详细展示了三大核心功能：**问题导航**、**智能问答**和**智能分析**。这三个功能被巧妙地设计在三个排列整齐、设计精美的方框中，每个方框都配以生动形象的插画，直观地向用户传达了项目的独特特点和显著优势。这一设计不仅提高了页面的视觉效果，也增强了用户与产品之间的互动体验。

为了激发用户的好奇心并引导他们更主动地参与到产品的体验中来，我们在介绍完核心功能后巧妙地运用了一个问句：“为什么要选择EduNavi？”这一问句不仅引起了用户的思考，也引导他们去探寻EduNavi的独特之处。紧接着，我们用“**guidance（专业指导）**”、“**share（资源共享）**”和“**improve（持续提升）**”这三个核心词来概括用户选择EduNavi的好处，为他们提供了明确的答案。

最后，我们进入算法功能介绍模块，这是项目**专业性和准确性的核心所在**。我们详细介绍了EduNavi所使用的先进机器学习算法和大数据分析技术，这些技术不仅确保了EduNavi能够为用户提供精准、个性化的服务，也展现了我们在教育科技领域的专业实力。通过这一模块的介绍，我们希望能够让用户更加深入地了解项目技术实力和专业性，从而更加信任并选择我们的产品。

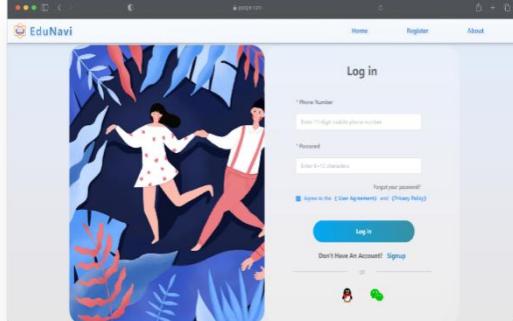


图4-6-2 登录页面

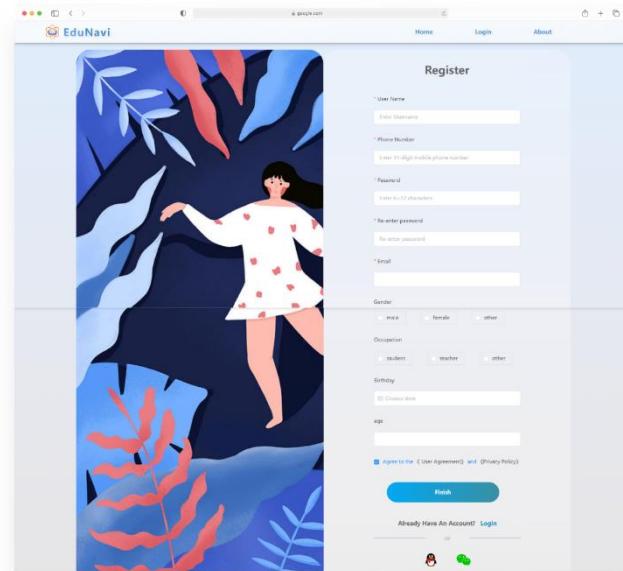


图4-6-3 注册页面

4.7.2 登录注册界面

登录页面作为用户访问平台的入口，其设计需简洁明了，同时保障用户信息安全。我们的登录页面采用右侧布局，将登录框体置于显眼位置，便于用户快速定位。登录框体包含清晰的输入字段，用于用户输入电话号码和密码。为保障用户密码安全，密码输入字段将采用隐藏形式显示。

除了基本的登录功能外，我们还为用户提供了“忘记密码？”的辅助功能，方便用户在忘记密码时快速找回。此外，用户在登录前需要勾选同意《用户协议》和《隐私政策》，以确保用户在使用平台时了解并遵守相关规定。

页面下方的“注册”链接，为尚未注册的新用户提供了便捷的注册通道，同时保持了页面的整体性和连贯性。

注册页面作为新用户了解平台并创建账户的重要界面，其设计需详尽且易于操作。我们的注册页面包含了多个必填字段，以确保收集到足够的信息以完成用户账户的创建。这些字段包括用户名、电话号码、密码设置（包括确认密码字段）、邮箱、性别选择、职业分类、出生日期和年龄等。

在密码设置上，我们要求用户设置一个6至12字符的密码，并在下一个字段中重复输入以确认，以增加账户的安全性。同时，我们还提供了日期选择器供用户选择真实的出生日期，或允许用户手动输入年龄。

在注册流程的末尾，用户需要勾选同意《用户协议》和《隐私政策》，以确保用户在使用平台前已充分了解并同意相关规定。完成所有信息填写后，用户点击“完成”按钮提交注册信息，系统将进行验证并创建用户账户。

此外，我们还为用户提供了社交媒体快捷注册方式，通过点击相应的社交媒体图标，用户可以使用已有的社交媒体账户快速完成注册流程。同时，页面底部的“登录”链接也为已注册用户提供了便捷的登录通道。

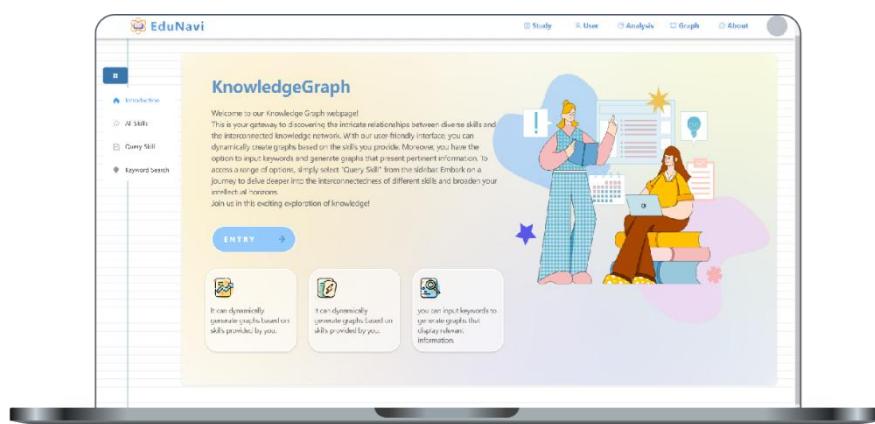


图 4-6-4 知识图谱页面一

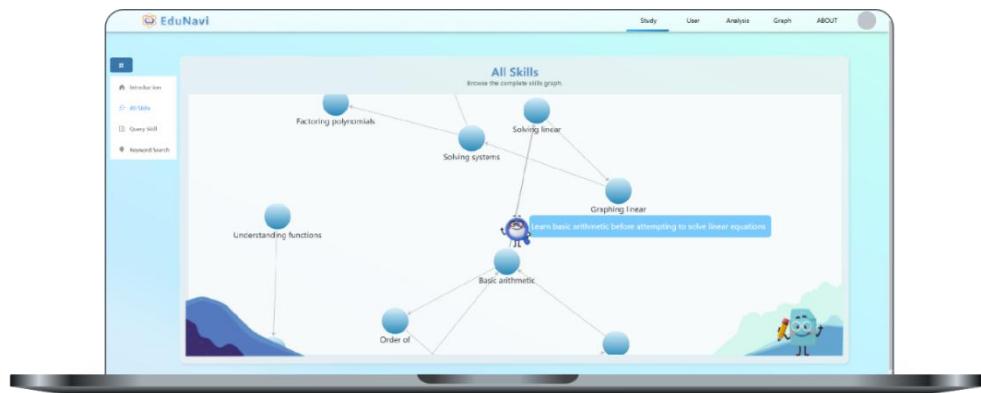


图4-6-5 知识图谱页面二

4.7.3 知识图谱页面

进入知识图谱页面后，用户会首先被侧边栏导航所吸引，这是我们为用户提供快速跳转至不同板块而精心设计的。侧边栏的简洁布局和清晰的标签，使用户能够轻松定位到所需的功能区域。

在介绍板块，我们采用了黄绿色为主色调，这一选择不仅令人耳目一新，更寓意着知识与智慧的蓬勃生长。右侧的插画设计巧妙地将知识图谱的概念具象化，为用户营造了一个生动有趣的探索环境。左侧的文字部分则详细介绍了知识图谱的功能和用户如何充分利用这一模块。

为了使用户能够更快地掌握知识图谱的使用方法，我们在左下角设置了三个栏目，分别介绍了**关键词搜索**、**查看全部技能**以及**技能搜索**三种功能。这些栏目通过图文结合的方式，直观展示了每种功能的特点和使用场景。此外，我们还提供了一个Entry按钮，用户可以通过点击这个按钮直接开始探索知识图谱的内容，体验其中的丰富与精彩。

在页面的整体设计上，我们注重了用户体验的流畅性和便捷性。用户不仅可以通过侧边栏选择想要的使用方法进入对应的板块，还能通过点击Entry按钮快速进入尝试第一个使用方法。这种设计既满足了用户的个性化需求，又提高了用户的操作效率。

在知识图谱的查看过程中，我们特别注重用户体验的细腻性和深度。当用户在浏览知识图谱时，通过精心设计的交互功能，我们使得信息的获取更加直观和高效。

具体来说，用户在查看知识图谱时，只需将鼠标悬停在任何一个结点或连接线上，界面便会迅速响应，展示详细的技能信息。这种即时反馈的设计，不仅提升了用户获取信息的效率，还极大地增强了用户的操作体验。同时，悬停提示还会指引用户了解在掌握当前结点技能之前，需要先掌握哪些前置技能，从而帮助用户更好地规划学习路径。

此外，为了满足不同用户的查看需求，我们还提供了知识图谱的放大缩小功能。用户可以根据自己的阅读习惯和关注重点，自由调整知识图谱的显示比例。放大功能可以让用户更深入地探索某一技能领域的详细内容和结构，而缩小功能则可以帮助用户快速概览整个知识图谱的全貌和脉络。这种灵活的缩放设计，使得知识图谱的查看更加便捷和个性化。

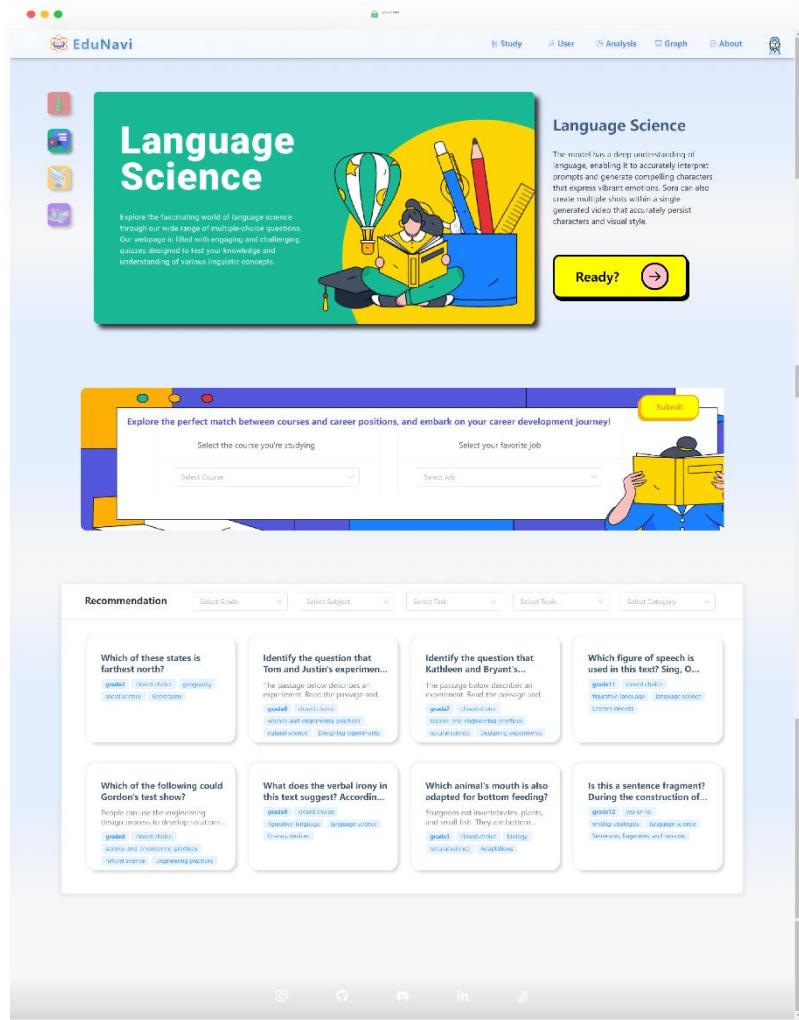


图 4-6-6 功能页面

4.7.4 功能页面

在构建我们的在线教育平台时，我们对功能页面的设计倾注了极大的心血，旨在为用户带来直观、高效且个性化的学习体验。以下是针对这些功能页面设计的详细介绍。

首先，做题导航入口页面以其高饱和度的色彩和精心规划的布局，即刻吸引用户的注意力。页面顶部的导航栏清晰展示了各个功能模块，使用户能够迅速定位所需内容。中央的科目概览部分，通过醒目的标题和不断轮播的描述，使用户能够直观了解

并选择不同的学习领域。科目切换控件的设计尤为巧妙，用户只需点击左侧的小图标，即可轻松浏览和选择不同科目，开启他们的学习之旅。整个页面在视觉层次上通过不同大小和透明度的卡片与组件叠加，营造出一种动态而富有深度的视觉体验，为用户带来更为沉浸的学习感受。

紧接着，**职业与课程匹配系统**板块的设计简洁直观，旨在帮助用户发现他们所学课程与职业之间的潜在联系。在页面的顶部，我们设置了一个明确标识的区域，用户可以在此输入课程和职业信息。通过下拉菜单，用户可以轻松选择和更改选项，实现个性化的匹配。匹配结果以直观的百分比和环形图表形式展示，同时辅以简明的文字反馈，使用户能够迅速理解匹配程度。整个页面布局清晰，功能明确，为用户提供了便捷的职业与课程匹配体验，助力他们规划未来的学习路径。

最后，**题目推荐系统**页面充分运用了用户协同过滤算法，为用户提供个性化的题目推荐服务。推荐题目卡片以简洁明了的方式展示题目内容，同时提供丰富的元数据标签，帮助用户快速了解题目详情。用户可以根据自己的需求，通过筛选控件进行定制化筛选，找到最适合自己的题目。

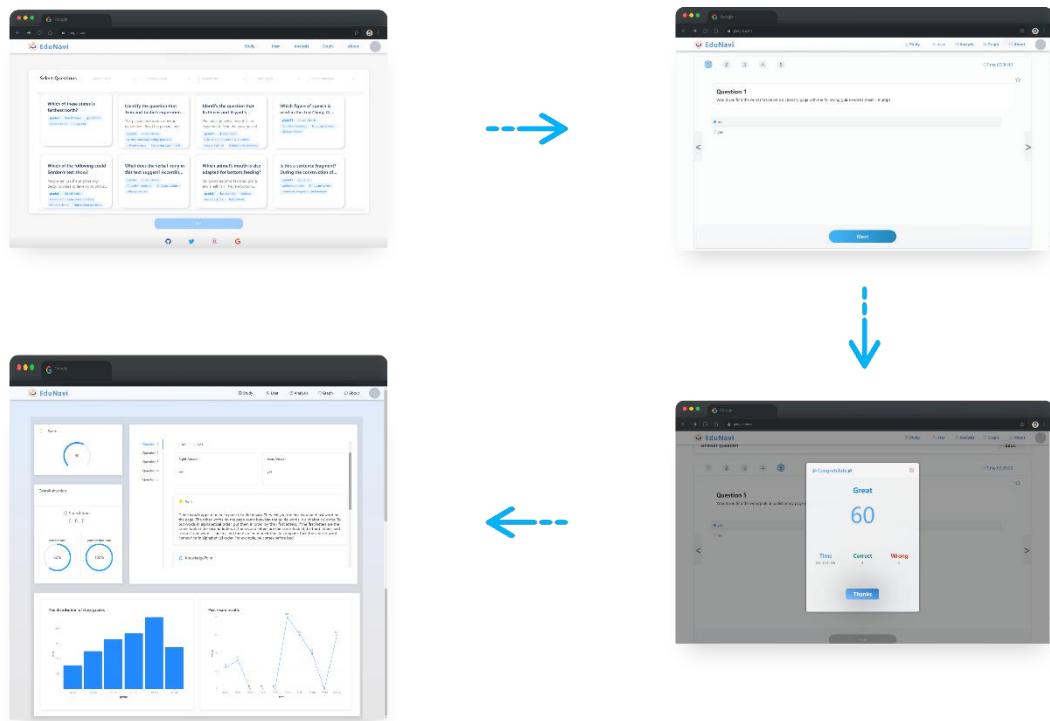


图4-6-7 作答界面

4.7.5 作答界面

在构建作答界面时，我们团队注重页面的设计，以确保用户能够享受到流畅、高效且个性化的学习体验。以下是关于作答界面的详细介绍，重点突出了页面设计的专业性和用户友好性。

首先，题目筛选页的设计充分考虑了用户的学习需求。在筛选区域，用户可以通

过下拉菜单选择特定的任务类型、年级、学科、话题和类别，从而定制自己的搜索条件。系统会根据用户的筛选标准，在页面中央以卡片形式展示相应的题目。这种设计使得用户能够迅速找到符合自己学习目标的题目，提高了学习效率。

当用户准备开始做题时，系统会弹出一个定制化的做题弹窗。在这个弹窗中，用户可以输入或选择计划练习的题目数量，并设定完成练习的时间限制。这种个性化的设定使得用户能够根据自己的学习节奏和时间安排进行练习，增加了学习的灵活性。用户完成设定后，点击“Start”按钮即可开始练习。

进入做题页面后，用户将看到一个专门为在线答题设计的交互式界面。答题区域位于页面中央，展示了当前的题目编号、题目内容以及相关的图像或插图。用户可以在下方的选项或文本输入框中选择或输入答案。页面左侧的箭头允许用户返回上一题，右侧的箭头则用于前进到下一题。此外，页面右上角还设有一个计时器，实时更新用户答题所用的时间，帮助用户管理答題节奏。页面底部的横向滚动题目导航栏则提供了快速跳转到任意题目的功能。

答题结束后，系统会弹出一个题目结算弹窗，对用户的练习情况进行总结和反馈。弹窗中首先以“Congratulate”标识开始，传达积极的用户反馈，并突出显示用户本次练习获得的分数。接着，弹窗会显示完成练习所用的总时间、正确和错误的题目数量等绩效指标。用户确认信息无误后，可以点击“Finish”按钮关闭弹窗并结束练习。

进入题目结算页面后，用户将获得一个全面的学习表现评估。页面左侧顶部的仪表盘以百分比形式表示用户答对题目的比例，为用户提供了快速直观的绩效概览。同时，页面还展示了答题速率、正确/错误比例等详细绩效指标，使用户能够全面了解自己的学习表现。此外，页面还包含了绩效分析图表，如题目得分分布图，帮助用户了解自己在班级内的相对表现。

在题目结算页面，我们还特别加入了答案反馈、学习建议以及大语言模型解释题目的功能。用户所选的答案旁边会标明正确与否，并给出正确答案以供对比和学习。同时，系统还会提供教育性课外指导，如正确阅读地图的方法或其他参考材料的链接，旨在帮助用户提高学习效率。大语言模型会根据用户的答题情况提供个性化的解释，帮助用户更好地理解和掌握知识点。

最后，我们的系统还基于协同过滤算法为用户提供个性化的题目推荐。通过分析用户之前的答题记录、准确率和回答速度等数据，系统会推荐符合用户学习需求和兴趣爱好的题目。这种个性化的推荐不仅能够帮助用户巩固已掌握的知识，还能够引导他们探索新的学习领域，实现持续的学习和成长。

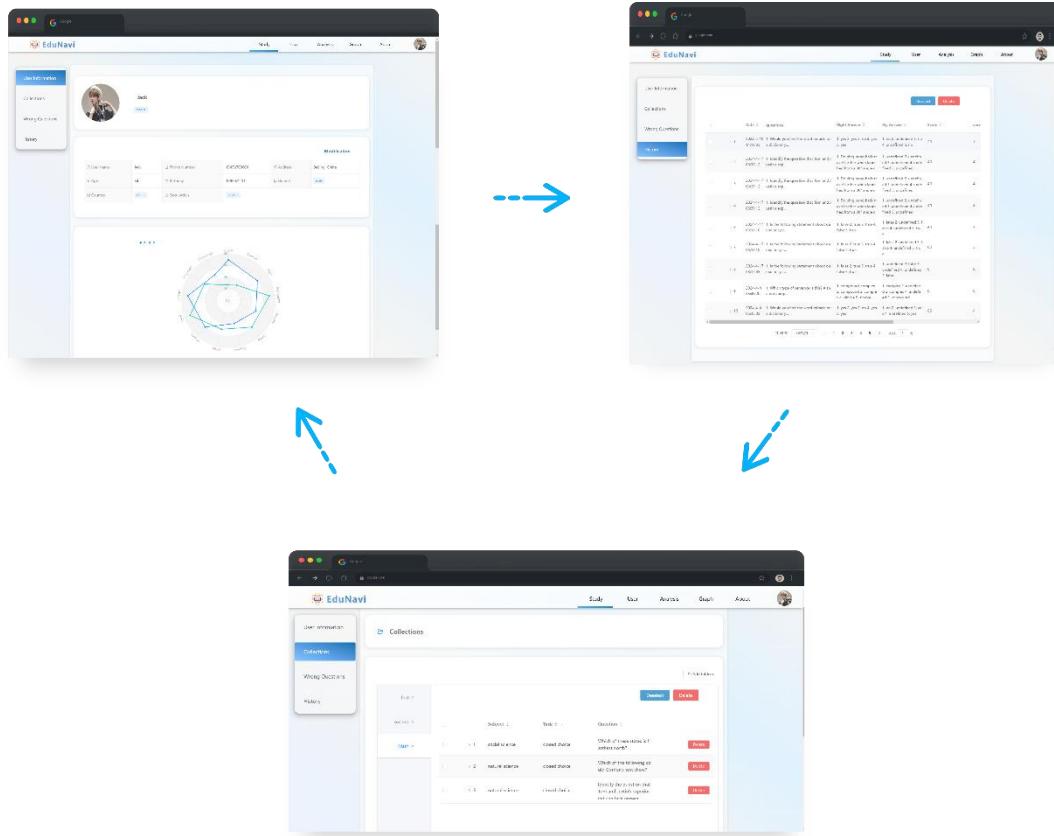


图4-6-8 用户信息页面

4.7.6 用户信息页面

在页面中央的核心区域，用户的基本信息得以清晰展示，包括姓名、联系方式、年龄、出生日期等关键字段，为用户提供了一个全面且易于查阅的个人档案视图。此外，我们巧妙地融入了雷达图技术，为用户呈现了一个全面的技能评估视图，使他们能够直观地了解自己在不同学科和技能领域中的表现，从而有针对性地规划学习路径。

通过侧边导航栏，用户能够流畅地跳转至所需的功能板块，包括**用户信息**、**错题记录**、**题目收藏**以及**历史题目**等四个核心区域。在“收藏题目”页面中，我们以条目化的形式清晰展示了用户收藏的题目，每个条目都详细标注了科目分类、题型以及题目摘要，使用户能够迅速定位并找到所需的题目。同时，我们提供了强大的管理功能，用户可以通过点击“删除”按钮轻松移除不再需要的收藏，或者利用顶部的批量操作选项进行更高效的管理。此外，我们还引入了“添加文件夹”功能，支持用户对收藏题目进行分类管理，助力他们根据学科或主题进行分组，进一步提高复习效率。

在“错题”页面中，我们为用户打造了一个集中查看和复习答错题目的专区。通

过页面顶部的过滤标签，用户可以轻松筛选感兴趣的科目，快速定位到错题。错题列表以清晰的列表形式呈现，详细记录了题目编号、科目类别、任务类型及具体的错题内容。用户还可以根据科目或任务类型对错题进行排序，以便更有条理地进行复习。此外，每个错题条目前都设有选择框，用户可以通过勾选来选择单个或多个错题进行操作，如重新练习或移除，极大地提高了学习的灵活性和效率。

最后，我们精心设计了“历史做题记录”页面，旨在为用户呈现他们完成的题目的详细历史记录。该页面以表格形式清晰展示了做题日期、时间、题目内容、正确答案、用户答案以及得分等关键信息，使用户能够全面回顾自己的做题表现。同时，我们提供了用户答案与正确答案的直接对比功能，帮助用户识别错误并理解错误原因，从而提升学习效果。底部的分页导航控件使用户能够轻松在不同页面间切换，便于管理大量的做题数据。

4.7.7 博客页面

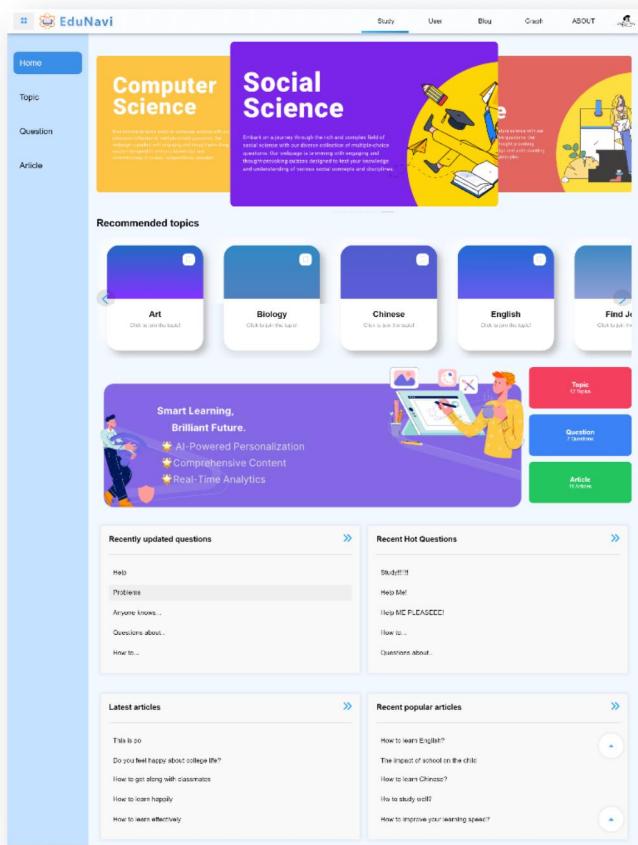


图4-6-9 博客首页

平台具有强大的社区支持，通过博客的形式为用户提供学习交流的平台。博客首页面设计简洁而专业，侧边导航栏精准地引导用户进入四大核心板块：首页、话题、问答、文章。页面一打开，顶部轮播图即刻呈现，生动展示我们学习平台丰富的题目

资源，为用户带来直观的学习预览。紧接着，推荐话题板块以滑动卡片的形式呈现，用户可通过点击左右箭头轻松浏览论坛内的所有相关话题，流畅地穿梭于不同讨论之间。

在首页的下方，四个精心编排的列表分别展示了最新问答、最新文章、最热问答、最热文章，用户可根据个人兴趣快速跳转至心仪的内容。同时，侧边箭头为用户提供了灵活的导航选项，进一步提升了浏览的便捷性。

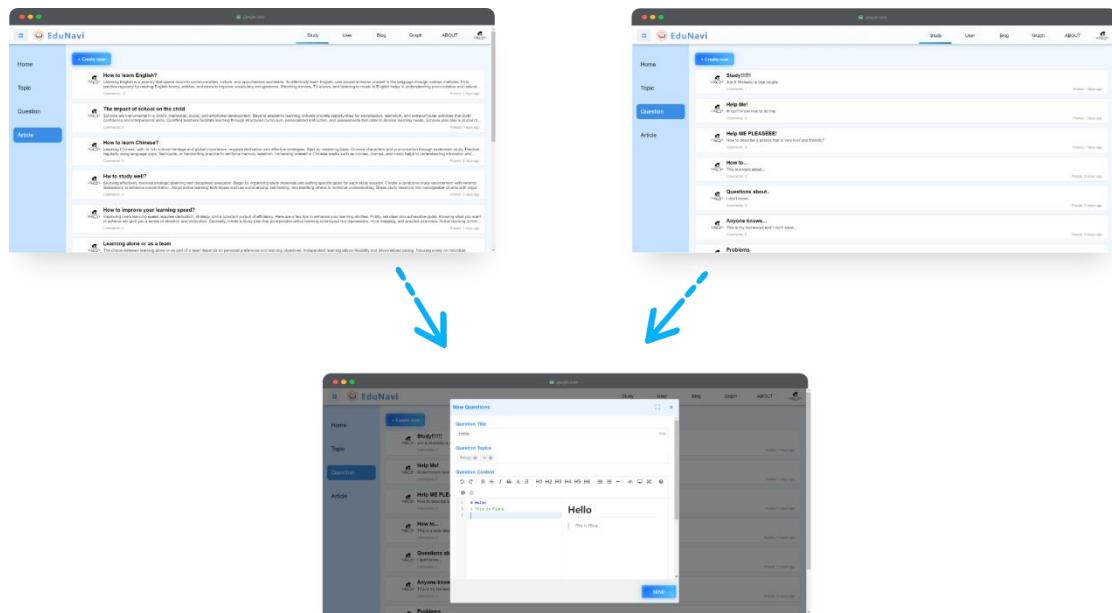


图4-6-10 问答和文章板块及编辑框

进入问答和文章问答板块，用户将看到由社区成员发布的精彩文章和问答。每篇文章和问答都清晰标注了发送时间和发送用户的头像，为用户构建了一个专业而亲近的阅读环境。在左上角，用户可点击“create”按钮，启动创作流程。点击后，一个对话框将弹出，允许用户进行文本编辑，为作品命名，并选择相关话题。特别值得一提的是，正文编辑支持markdown格式，用户可实时预览排版效果，确保内容的专业性和可读性。

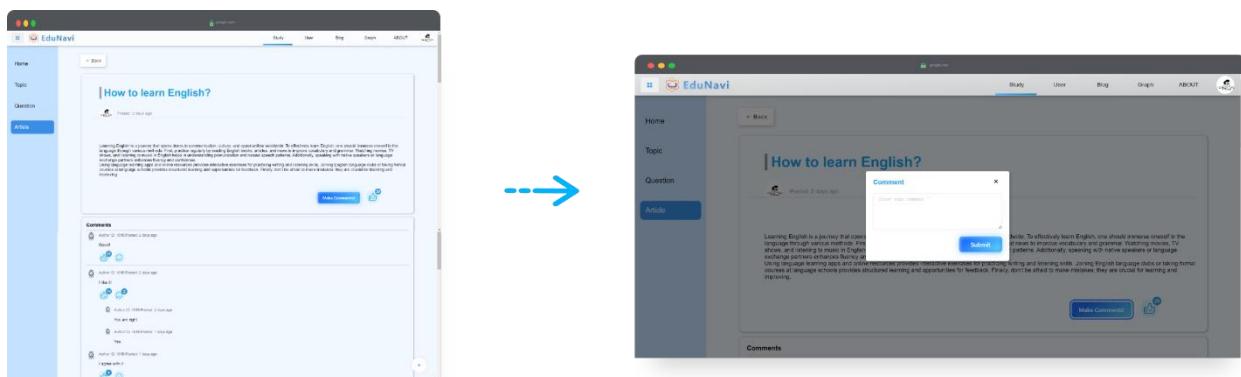


图4-6-11 文章详情页面

当用户点击感兴趣的文章时，页面将平滑跳转至详情页。在这里，用户可以深入阅读文章的具体内容，并通过点赞、评论等方式与其他读者互动。发送嵌套评论时，系统将自动弹出输入框，方便用户快速输入评论，进一步促进了社区内的交流与互动。

5. 创新与特色

5.1 创意

5.1.1 设计理念

EduNavi 项目的设计理念在于通过现代化技术手段，融合人工智能、大数据和云计算，打造一个智能、高效且个性化的教育平台。项目融合多种教育理论，如知识空间理论、最近发展区理论和建构主义理论，确保系统的设计科学性和教育效果。知识空间理论帮助构建全面的学科知识库，明确知识点之间的关联，从而为系统提供一个结构化的知识网络，支持精确的知识掌握评估和个性化学习路径规划。最近发展区理论指导教学干预的精准性，确保学生在适合的区域内得到最大的发展，通过分析学生当前能力和潜力，优化教学策略和资源分配。建构主义理论推动个性化学习路径的设计，强调学生主动构建知识，使学习过程更加主动和高效。通过这样的设计理念，EduNavi 不仅提升了教育的科学性和系统性，还增强了学生的学习积极性和效果。

5.1.2 题的创新性

EduNavi 项目选题的创新性体现在其针对传统教育中的痛点问题提出了新颖的解决方案。自动阅卷模型通过自然语言处理和机器学习技术，大幅提高评分的效率和准确性，解决了教师在大规模考试中批改试卷的难题。知识追踪模型通过大数据分析和动态学习路径调整，帮助学生和教师实时了解学习进度，优化教学策略，提升学习效果。联邦学习模型在保障数据隐私的同时，实现了跨机构的数据共享和模型训练，克服了教育数据孤岛的问题。此外，项目引入了前沿的大模型(LLM)，例如ChatGLM2-6B，以提升自然语言处理和智能交互的能力，为学生和教师提供更加智能化的服务。选题不仅具有现实意义，还具有前瞻性，能够引领教育技术的发展潮流，为教育行业带来深远的影响。

5.2 技术

5.2.1 先进性

EduNavi 项目应用了多种前沿技术，包括大规模自然语言处理、深度学习和分布式计算。自动阅卷模型采用基于 LSTM 和 BERT 的混合模型，通过预训练语言模型提取文本特征，并利用 LSTM 网络捕捉长距离的文本依赖性，以及大模型微调提升评分的精度和效率。知识追踪模型采用 KTPromptCast 技术，将学生的历史表现和交互数据转化为自然语言形式输入，利用大模型的理解能力预测学生在新问题上的表现。联邦学习模型结合 BERT 技术，实时分析职业市场需求和教育内容的匹配度，提供精准的职业规划和就业指导。此外，系统还集成了 ChatGLM2-6B 模型，进一步提升了系统在自然语言理解和生成方面的能力，为用户提供更加智能化和人性化的服务。这些

技术的应用，使得 EduNavi 系统在技术先进性方面处于领先地位，为教育行业的数字化转型提供了坚实的技术基础。

5.2.2 综合性

项目综合运用了多种先进技术，形成了一套完整的教育解决方案。自动阅卷模型结合PaddlePaddle深度学习框架的手写体识别功能实现准确的评分任务；知识追踪模型结合大数据分析和个性化推荐技术，为每位学生定制学习路径；联邦学习模型通过分布式架构，实现跨机构数据协作，提高模型的泛化能力和适应性。基础模型层依托领域知识层的数据，实现了自动阅卷评分模型、知识追踪模型和基于联邦学习的教育-就业匹配模型。还有用户接口层为用户提供交互和反馈功能。整个系统通过综合应用这些前沿技术，构建了一个高效、智能的教育平台，满足了不同用户的多样化需求。项目的综合性还体现在其技术路线的多样性和协同性上，通过集成不同领域的技术，形成了一个功能齐全、性能优越的教育系统。

5.3 实用

5.3.1 实用价值

EduNavi 项目在教育领域具有极高的实用价值。自动阅卷模型通过高效的评分机制，减少教师的工作量，提高工作效率；知识追踪模型帮助教师和学生实时了解学习进度和知识掌握情况，优化教学策略，提升学习效果；联邦学习模型保障教育数据的隐私和安全，为跨机构协作提供技术支持，帮助学生更好地适应未来职场的发展，并助力企业挖掘和培养所需的人才。系统集成的大规模语言模型 ChatGLM2-6B，使得智能化评分和个性化反馈更加精准和高效，进一步提升了系统的实用价值。项目的实用价值还体现在其对教育质量的提升和教育资源的优化配置上，通过智能化技术手段，使得教育过程更加科学、高效和个性化。

5.3.2 市场潜力

在当前教育数字化转型的背景下，EduNavi 项目具有巨大的市场潜力。其技术优势和创新性使其在 K12 教育、高等教育和职业培训等多个领域具有广泛的应用前景。项目不仅服务于教育机构，还可以为教育科技公司提供技术支持，具备广泛的商业化可能性。基于联邦学习的教育-就业匹配模型，通过纵向联邦学习和 BERT 技术，实时分析职业市场需求和教育内容的匹配程度，提供精准的职业规划和就业指导，为学生提供有效的职业建议，助力他们更好地适应职场变化。EduNavi 项目通过其先进的技术和创新的应用，具备极高的市场拓展潜力，能够在全球教育市场中占据重要位置。

5.4 设计

5.4.1 技术路线

EduNavi 项目采用分层的智能导学系统架构，包括领域知识层、基础模型层和用户接口层。领域知识层构建了全面的学科知识库和教学策略库，通过知识空间理论建立知识点间的关联和逻辑框架。基础模型层基于最近发展区理论，实现了自动阅卷评

分模型、知识追踪模型和基于联邦学习的教育-就业匹配模型。用户接口层依托建构主义理论，提供个性化反馈和直观操作界面，实现大模型RLHF生成多样范例，基于协同过滤的个性化题目推荐以及构建个性化知识图谱。系统还集成了 ChatGLM2-6B 模型，进一步提升了用户交互的智能化和人性化水平。技术路线的设计确保了系统的稳定性和可扩展性，通过分层架构和模块化设计，使得系统能够灵活应对不同的教育场景和需求。

5.4.2 系统架构

本项目的系统架构精心遵循了现代Web应用程序的分层设计原则，旨在通过精心设计的四个核心层次——展示层、通信层、服务层和数据层——显著提升系统的可扩展性、可维护性和性能。在展示层，我们运用了包括jQuery、Vue.js在内的前端框架，以及HTML、CSS、JavaScript等标准Web技术，结合AntV等数据可视化库，为用户提供了直观、吸引人且操作流畅的用户界面（UI）和用户体验（UX）。通信层方面，我们选择了NGINX服务器作为反向代理，通过优化请求处理流程，确保用户请求的高效转发和处理。同时，我们采用了Spring Boot框架的Controller模块，以标准化的方式处理前后端通信，确保了通信的可靠性和高效性。服务层作为系统的核心，承载了所有的核心业务逻辑。我们设计了多个服务组件，每个组件负责特定的业务功能，以实现高内聚、低耦合的模块化设计。同时，为了提升数据处理速度和响应能力，我们与Redis缓存系统进行了深度集成，利用缓存机制加速数据访问。在数据层，我们采用了Mybatis Plus作为对象关系映射（ORM）工具，它简化了与MySQL数据库的交互过程，使得数据库操作更加高效和简洁。同时，我们严格遵循数据库设计的最佳实践，确保数据的持久化、管理效率、完整性和一致性。整体而言，这种分层架构的设计使得系统各层次之间高度模块化、松耦合，为系统的后续扩展和维护提供了坚实的基础。无论是在功能扩展、性能优化还是故障排查方面，这种架构都展现出了其独特的优势。

5.4.3 用户界面

用户界面设计注重用户体验，采用响应式设计，确保在各种设备上的良好显示效果。教师界面提供简洁明了的试卷批改和教学管理功能；学生界面提供个性化的学习建议和进度反馈；管理界面为教育机构提供全面的数据分析和系统管理功能。用户接口层直接与用户互动，提供个性化反馈和直观操作界面，利用大模型 RLHF 生成多样范例提供个性化解题辅助，通过综合用户答案、标准答案、相关知识点和难度级别等信息，为学生提供定制化的学习提示。此外，系统还通过 ChatGLM2-6B 模型实现智能化的自然语言交互，提升用户体验。个性化知识图谱的构建，则结合了领域知识层的结构化知识和基础模型层的用户学习数据，为每位用户创建一个定制的学习路线图。

5.5 效果

5.5.1 系统功能的有效性

EduNavi 项目的系统功能通过全面的测试和优化，确保了其有效性。自动阅卷模型通过大规模数据训练和微调，实现了高效、准确的自动评分；知识追踪模型通过动态分析学生的学习行为和历史数据，实时调整学习路径和教学策略，提高了教学效果；基于联邦学习的教育-就业匹配模型，通过跨机构的数据协作和智能分析，为学生提供精准的职业规划和就业指导。系统功能的有效性还体现在其对不同教育场景的适应能力上，能够灵活应对从基础教育到高等教育的各种需求，为教育过程提供全方位的支持。

5.5.2 系统功能的复杂度

EduNavi 项目集成了多种先进技术，系统功能的复杂度体现在其多层次、多模块的设计上。基础模型层包括自动阅卷评分模型、知识追踪模型和基于联邦学习的教育-就业匹配模型，每个模型都包含多个算法和技术，如 LSTM、BERT、KTPromptCast 和 P-Tuning 等。系统通过分层架构和模块化设计，将复杂的技术和算法有机结合，实现了功能的协同高效运作。此外，系统还采用了前沿的大规模语言模型 ChatGLM2-6B，通过先进的自然语言处理技术，提升了系统的智能化水平和用户体验。用户接口层通过智能交互和个性化推荐，实现了复杂功能的简洁操作，确保用户能够方便快捷地使用系统各项功能。

参考文献

- [1]Wang, Q. , & Lin, E. (2012). Incorporating ZPD into traditional Chinese education system. *China Educational Technology*.
- [2]Wang, Y. (2011). Intelligent tutoring systems: toward the creation of a computer-based Socratic tutor. *Journal of Applied Research in Education*.
- [3]Li, M. , & Chen, P. (2014). Applying constructivism in instructive design in China. *China Educational Technology*.
- [4]Kaveh Taghipour and Hwee Tou Ng A Neural Approach to Automated Essay Scoring.
- [5]Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, pages 1882 – 1891, Austin, Texas, November 1–5, 2016. c2016 Association for Computational Linguistics
- [6]Youmna Farag , Helen Yannakoudakis and Ted Briscoe. Neural Automated Essay Scoring and Coherence Modeling for Adversarially Crafted Input. arXiv:1804.06898v3
- [7]JIN XUE, XIAOYI TANG and LIYAN ZHENG. A Hierarchical BERT-Based Transfer Learning
- [8]Approach for Multi-Dimensional Essay Scoring. Published in: IEEE Access. IEEE, 125403 – 125415.
- [9]I. Beltagy, K. Lo, and A. Cohan, ‘‘SciBERT: A pretrained language model for scientific text, ’ ’ 2019, arXiv:1903.10676. [Online]. Available: <http://arxiv.org/abs/1903.10676>
- [10]Burr Settles. 2012. Active Learning. *Synthesis Lectures on Artificial Intelligence and Machine Learning* 6, 1 (2012), 1 – 114.
- [11]Neshaei, S. P., Davis, R. L., Hazimeh, A., Lazarevski, B., Dillenbourg, P., & Käser, T. (2023). Towards Modeling Learner Performance with Large Language Models.
- [12]Xue, H. , & Salim, F. D. (2023). PromptCast: A New Prompt-based Learning Paradigm for Time Series Forecasting.

附录

附录一：项目投资意向书一

项目投资意向书

甲方：河源市源盛绿化有限公司
乙方：EduNavi 教育公司

联系方式：13502310866
联系方式：13538835651

甲乙双方本着友好合作、平等互利、共谋发展的原则，经充分协商，特订立本合同，以供双方履行和遵守：

一、保密条款

本协议所指保密信息是指：乙方向甲方提供的资料，甲方具有保密义务。同时，乙方从甲方获得的与合作有关或因合作产生的任何商业、营销或其他性质的资料，乙方具有保密性义务。

甲乙双方的权利和义务：

- 1、双方保证该保密信息仅用于与合作有关的用途或目的。
- 2、双方各自保证对对方所提供的保密信息予以妥善保存。
- 3、双方各自保证对对方所提供的保密信息按照本协议约定予以保密，并至少采用适用于对自己的保密信息同样的保护措施进行保密。

二、投资条款

1. 投资方式

甲方以增资协议向乙方公司进行投资，所投资资金用于乙方产品销售，不得挪为他用。

2. 投资金额

甲方投资总金额：(200 万)，根据乙方目标公司的股份比例对乙方尽职调查后的情况，甲乙双方协商确定。

3. 甲乙投资乙方的简要流程

甲乙双方完成签订投资合作框架协议之后，甲方安排相关人员到乙方展开尽职调查，乙方需要全力配合。甲方形成尽职调查报告后，~~投资人审核~~，审批完成后，甲乙双方协商签署正式的投资合作协议书。

4. 本协议仅为双方投资意向约定，不具有任何法律效力，具体事宜以双方正式签署的《投资协议》为准。

甲方：河源市源盛绿化有限公司 盖章/签名：

乙方：EduNavi 教育公司

盖章/签名：徐子琳

附录二：项目投资意向书二

项目投资意向书

甲方：珠海市威威纸业有限公司
乙方：EduNavi 教育公司

联系方式：13823054631
联系方式：13538835651

甲乙双方本着友好合作、平等互利、共谋发展的原则，经充分协商，特订立本合同，以供双方履行和遵守：

一、保密条款

本协议所指保密信息是指：乙方向甲方提供的资料，甲方具有保密义务。同时，乙方从甲方获得的与合作有关或因合作产生的任何商业、营销或其他性质的资料，乙方具有保密性义务。

甲乙双方的权利和义务：

- 1、双方保证该保密信息仅用于与合作有关的用途或目的。
- 2、双方各自保证对对方所提供的保密信息予以妥善保存。
- 3、双方各自保证对对方所提供的保密信息按照本协议约定予以保密，并至少采用适用于对自己的保密信息同样的保护措施进行保密。

二、投资条款

1、投资方式

甲方以增资协议向乙方公司进行投资，所投资资金用于乙方产品广告宣传，不得挪为他用。

2、投资金额

甲方投资总金额：(100万)，根据乙方目标公司的股份比例对乙方尽职调查后的情况，甲乙双方协商确定。

3、甲乙投资乙方的简要流程

甲乙双方完成签订投资合作框架协议之后，甲方安排相关人员对乙方尽职调查，乙方需要全力配合。甲方形成尽职调查报告后，报投资人审批，审批完成后，甲乙双方协商签署正式的投资合作协议书。

4、本协议仅为双方投资意向约定，不具有任何法律效力，具体事宜以双方正式签署的《投资协议》为准。

甲方：珠海市威威纸业有限公司 盖章/签名： 

乙方：EduNavi 教育公司 盖章/签名： 

附录三：项目投资意向书三

项目投资意向书

甲方：广州市锦鸿塑料模具有限公司
乙方：EduNavi 教育公司

联系方式：
联系方式：13538835651

甲乙双方本着友好合作、平等互利、共谋发展的原则，经充分协商，特订立本合同，以供双方履行和遵守：

一、保密条款

本协议所指保密信息是指：乙方向甲方提供的资料，甲方具有保密义务。同时，乙方从甲方获得的与合作有关或因合作产生的任何商业、营销或其他性质的资料，乙方具有保密性义务。

甲乙双方的权利和义务：

- 1、双方保证该保密信息仅用于与合作有关的用途或目的。
- 2、双方各自保证对对方所提供的保密信息予以妥善保存。
- 3、双方各自保证对对方所提供的保密信息按照本协议约定予以保密，并至少采用适用于对自己的保密信息同样的保护措施进行保密。

二、投资条款

1、投资方式

甲方以增资协议向乙方公司进行投资，所投资资金用于乙方产品平台开发与维护，不得挪为他用。

2、投资金额

甲方投资总金额：(200 万)，根据乙方目标公司的股份比例对乙方尽职调查后的情况，甲乙双方协商确定。

3、甲乙投资乙方的简要流程

甲乙双方完成签订投资合作框架协议之后，甲方安排相关人员对乙方展开尽职调查，乙方需要全力配合。甲方形成尽职调查报告后，报投资人审批，审批完成后，甲乙双方协商签署正式的投资合作协议书。

4、本协议仅为双方投资意向约定，不具有任何法律效力，具体事宜以双方正式签署的《投资协议》为准。

甲方：广州市锦鸿塑料模具有限公司

盖章/签名：

乙方：EduNavi 教育公司

盖章/签名：徐子渊

附录四：国家级大学生创新创业训练计划竞赛项目1项

附件： 华南师范大学2024年国家级、省级大创计划推荐立项结果汇总表

序号	归属学院	项目编号	项目名称	项目类型	负责人	导师	级别	项目类别
1	阿伯丁数据科学与人工智能学院	202410574003	基于深度学习的端到端多模态情感分析系统	创新训练	郑博	贺超	国家级	一般项目
2	阿伯丁数据科学与人工智能学院	202410574022	基于机器学习的早产儿视网膜病变检测算法研究	创新训练	刘俊杰	沈映珊	国家级	一般项目
3	阿伯丁数据科学与人工智能学院	202410574064	以知识追踪为导向的智能导学评分系统	创新训练	徐子珊	杨欢	国家级	一般项目
4	阿伯丁数据科学与人工智能学院	S202410574001	基于大语言模型的金融咨询分类辅助系统	创新训练	黄睿敏	穆尔哈提·阿卜拉	省级	一般项目
5	阿伯丁数据科学与人工智能学院	S202410574024	基于机器学习的中医舌象健康诊断	创新训练	杨铭哲	蔡洁仪	省级	一般项目
6	阿伯丁数据科学与人工智能学院	S202410574026	基于多模态大模型的医患影像分析诊断系统	创新训练	卢语丹	蔡礼华	省级	一般项目
7	阿伯丁数据科学与人工智能学院	S202410574042	基于计算机视觉和知识蒸馏技术的指针式仪表自动读数	创新训练	孙榕	蒋运承	省级	一般项目
8	阿伯丁数据科学与人工智能学院	S202410574046	有机新污染物数据库及分析平台的构建	创新训练	金可欣	陈欢	省级	一般项目
9	阿伯丁数据科学与人工智能学院	S202410574081	基于大模型的多模态情感识别	创新训练	陈垚充	陆柳杏	省级	一般项目
10	半导体科学与技术学院	202410574059	“光芒灯塔”——基于量子点超晶格近红外探测器的自动驾驶系统设计	创新训练	董宇	刘霄、陈洪宇	国家级	一般项目
11	半导体科学与技术学院	S202410574119	碱金属离子嵌入V2O5正极材料的制备及其储锌性能研究	创新训练	郑灿伟	刘铁忠	省级	一般项目
12	半导体科学与技术学院	S202410574120	二维双范德华异质结光电探测器及其忆阻器的构筑与神经形态应用研究	创新训练	周凯悦	高伟（半导体）	省级	一般项目
13	半导体科学与技术学院	S202410574147	半导体器件表面温度分析用高精度深紫外检测技术研究	创新训练	张铭皓	王幸福	省级	重点支持领域项目
14	材料与新能源学院	S202410574138	石墨烯场效应晶体管于高灵敏及便携式神经通量传感研究	创新训练	陈艳瑶	陶文艳	省级	一般项目
15	材料与新能源学院	S202410574160	基于凝胶聚合物准固态电解质锂电池的材料设计与性能优化	创新训练	陈伟涛	汝强	省级	一般项目

第1页，共16页

六千第

附件五：第十五届蓝桥杯全国软件和信息技术专业人才大赛数字科技创新赛全国选拔赛三等奖



附录六：2024网络技术挑战赛华南赛区三等奖



附件七：华南师范大学中国国际大学生创新大赛（2024）校赛铜奖

